Escalabilidad

Capacidad de un sistema p/ adaptarse a diferentes ambientes modificando los recursos del sistema.

Objetivo

Crecimiento respecto de:

- Tamaño. +Usuarios/recursos.
- Distribución geográfica. Dispersión.
- Objetivos administrativos del sistema.

Características de plataformas

- Plataformas p/ alta concurrencia.
 - Patrones conocidos.
 - Escalamiento automático.
 - Fuerte vínculo con infra/producto.
- Arquitecturas ad-hoc y personalizadas.
 - Necesidad de configuración y soporte.
 - Escalamiento manual / automatizado x humanos.
 - Posibilidad de migraciones.

Patrones de carga

- Predictable Burst.
- Unpredictable Burst.
- Periodic Processing (avg usage + períodos de inactividad).
- Start Small, Grow Fast.

Limitantes

- Arquitectura y algoritmos.
- Datos.
- Red (latencia, ancho de banda).
- Restricciones de negocio / locales.
- Presupuesto.

Técnicas

- Escalamiento **vertical**. +Recursos.
- Escalamiento horizontal.
 - Redundancia,
 - Balanceadores de carga,
 - Proximidad geográfica.
- Fragmentación de datos.
- Optimizar algoritmos. Performance, mensajería.
- Asincronismo. Limitado por negocio.
- Componentización -> separar servicios.

Elasticidad

Capacidad de un sistema p/ modificar dinámicamente los recursos adaptándose a patrones de carga.

Componentes

- Application Load Balancer. Ver a qué servicio/instancia le mandamos tráfico.
- Autoscaler.
 - Scale In: decrementar instancias.
 - Scale Out: incrementar instancias.
 - En función de **métricas**.
- Monitoring Automático. Métricas sobre CPU, memoria, I/O, networking, etc. p/ c/ servicio/instancia.
- Ejemplos:
 - AWS: Amazon ELB, Amazon Autoscaling, Amazon CloudWatch.
 - K8s: K8s Service, Horizontal Pod Autoscale, K8s Metrics Server.