Sistemas Distribuidos I
(75.74)

Data Intensive Applications

Particiones y Replicación. Distributed Shared Memory (DSM). Distributed File Systems (NFS, HDFS). Big Table.

Docentes

- Pablo D. Roca
- Ezequiel Torres Feyuk
- Guido Albarello
- Ana Czarnitzki
- Cristian Raña

Agenda

- **Datos en Sistemas de Gran Escala**
- Partición y Replicación
- Distributed Shared Memory (DSM)
- Distributed File Systems (DFS)
- Big Table

Datos en Sistemas de Gran Escala | Flujo de Datos

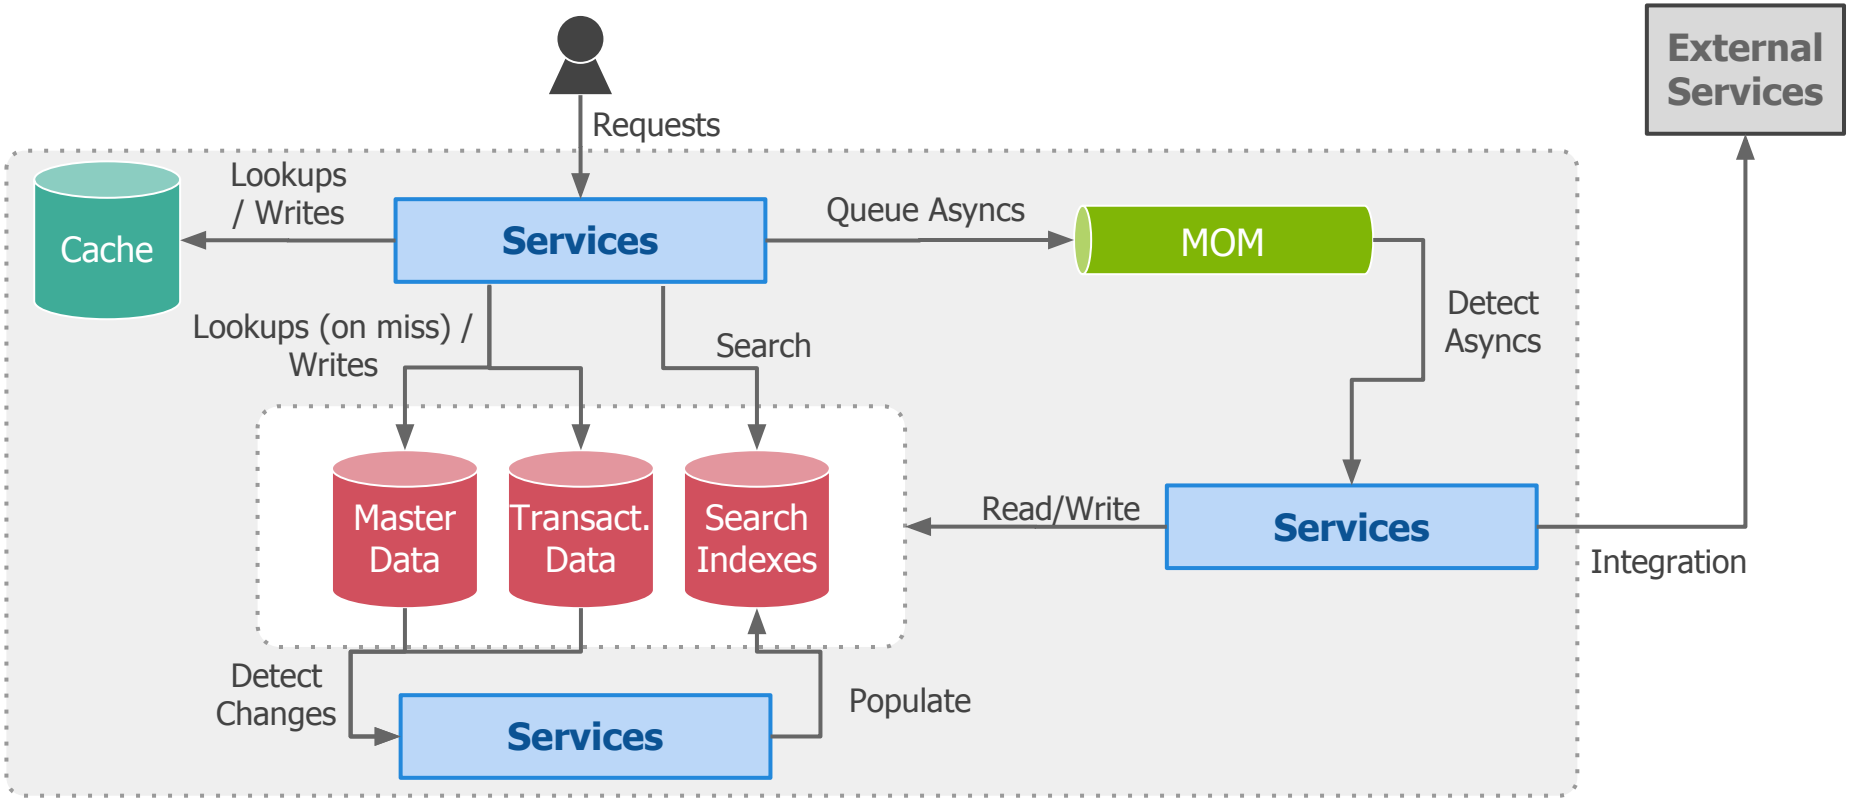

Transac. Data | Relacional vs NoSQL

Enfoques que nacen en '60s y '70s: *hierarchical*, *network & relational model.*

Relacional

- Predomina hasta 2010 con la estandarización de SQL. Almacenamiento en tablas y filas.
- Buen soporte para *joins*, relaciones *many-to-one* o *many-to-many*

No Relacional | Not Only SQL (NoSQL)

- A partir del 2010, la industria imponen otros almacenamientos: clave-valor, documentales, orientadas a grafos, columnares.
- Beneficios claros para modelos afines: sin relaciones, one-to-many (jerárquicos), alta conectividad (grafos).
- Se adapta mejor a modelos con esquemas (*schemas*) cambiantes o no definidos.

Transac. Data | Transaccional (OLTP) vs *Analytics* (OLAP)

Enfoques que nacen en '60s y '70s: *hierarchical, network & relational model.*

- **Online Transaction Processing (OLTP):** Orientado a unidades lógicas: grupos de *reads/writes* (o transacciones). No necesariamente ACID.
- **Online Analytics Processing (OLAP):** Orientado a analizar el conjunto de los datos.

	OLTP	**OLAP**
Patrón de *Read*	Pocos registros. Búsqueda por claves.	Agregación de muchos registros.
Patrón de *Write*	Acceso aleatorio. Registros pequeños.	Importaciones *batch* (ETLs) o *Streams*.
Uso Principal	Info maestra y transaccional p/usuarios	Exploración de datos interno. Análisis estadístico.
Datos	Instantánea de los datos en el momento actual. Tamaños de MBs-GBs.	Histórico de los datos. Tamaños de TBs-PBs.

Almacenamiento | Relacional

- Normalmente: un archivo de almacenamiento por tabla.
- Relaciones entre tablas por *foreign-keys*
- Lectura de toda la fila para retornar proyecciones.

Tabla: Sales

date_id	product_id	quantity	price	discount
20100101	100	2	200.00	NULL
20100101	101	1	400.00	50.00
20100102	100	3	300.00	NULL
20100102	103	2	100.00	NULL
20100102	103	10	500.00	NULL

Tabla: Products

product_id	Name	price
100	Prod1	100.00
101	Prod2	450.00
103	Prod3	50.00

Almacenamiento | Columnar

- Normalmente: Un archivos de almacenamiento por columna.
- Lectura de cada columna para retornar proyecciones.
- Grandes beneficios para compresión, lectura y agregaciones.

Sales

Columna	Contenido
date_id	20100101,20100101, 20100102, 20100102, 20100102
product_id	100, 101, 100, 103, 103
quantity	2, 1, 3, 2, 10
price	200.00, 400.00, 300.00, 100.00, 500.00
discount	NULL, 50.00, NULL, NULL

Products

Columna	Contenido
product_id	100, 101, 103
name	Prod1, Prod2, Prod3
price	100.00, 450.00, 50.00

Almacenamiento | Cubos de Información

- Normalmente: mantienen vistas materializadas con pre-cálculos estadísticos.
- Se crean grillas agrupadas por diferentes dimensiones.
- Operaciones como SUM, COUNT, MAX, MIN, AVG se consultan a estos cubos.

Ej.: Cubo: date_id x product_id,quantity

		quantity				
		1	**2**	**3**	**10**	**total**
product_id		**100**	**101**	**103**	**total**	…
date_id	**20100101**	200.00	400.00	0.00	600.00	…
	20100102	300.00	0.00	600.00	900.00	…
	total	500.00	400.00	600.00	1500.00	

Agenda

- Datos en Sistemas de Gran Escala
- **Partición y Replicación**
- Distributed Shared Memory (DSM)
- Distributed File Systems (DFS)
- Big Table

Replicación | *Leader based*

- Una réplica se designa como *master* o *leader*.
- Otras réplicas se designan *mirrors*, *slaves* o *followers*.
- Sólo se aceptan escrituras en el *leader*.
- Tanto *leader* como *followers* aceptan lecturas.
- La replicación puede ser síncrona o asíncrona.
- Problemas de la replicación:
  - *Read your own writes, Monotonic reads*

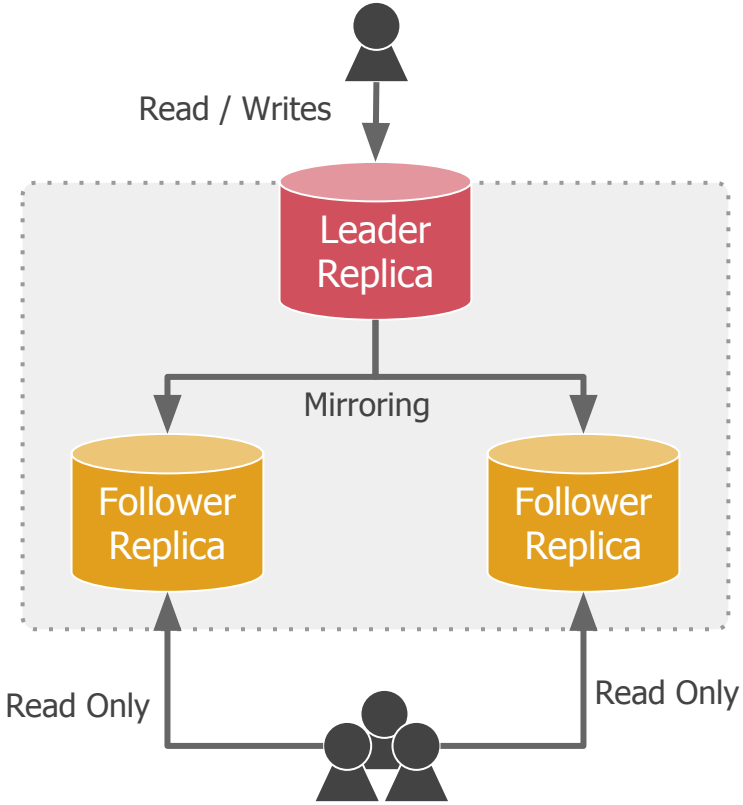

Replicación | *Multi-leader based*

- Modelo normal en escenarios de múltiples data-centers.
- Frente a caídas de un data-center, se puede promover al otro como líder global.
- Problemas de la replicación:
  - Idem a leader based más la posibilidad de conflictos por concurrencia.
- Otros inconvenientes:
  - manejo de triggers, claves incrementales, integridad de relaciones.

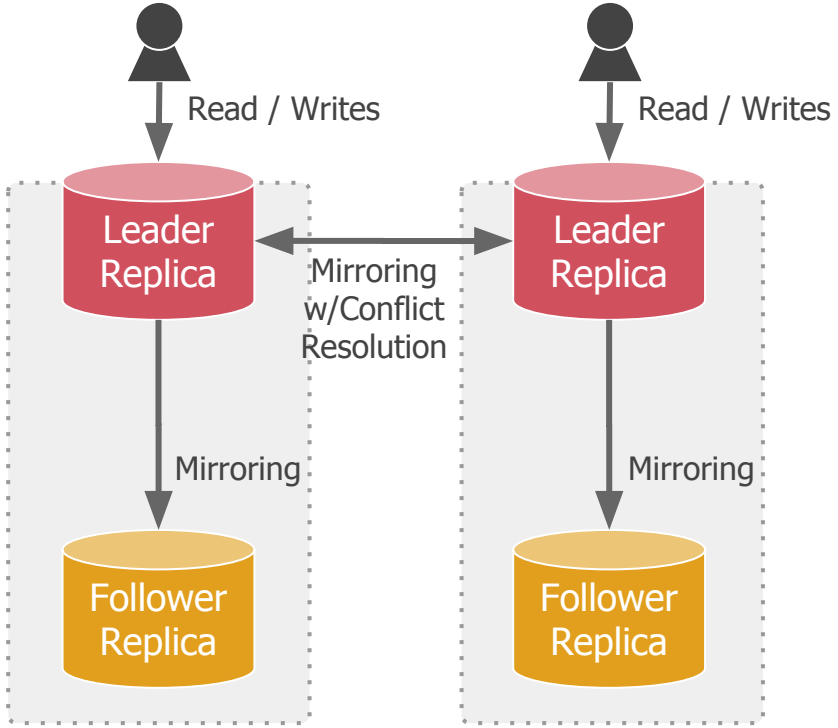

Replicación | *Leaderless based*

- Sistema de replicación totalmente distribuido.
- Las réplicas deben sincronizarse mutuamente.
- Se puede definir topologías para la sincronización:
  - anillo, jerárquicas, todos contra todos
- Los conflictos son muy frecuentes a menos que se particione.
- Otra alternativa es conseguir un consenso entre las réplicas para aplicar escrituras

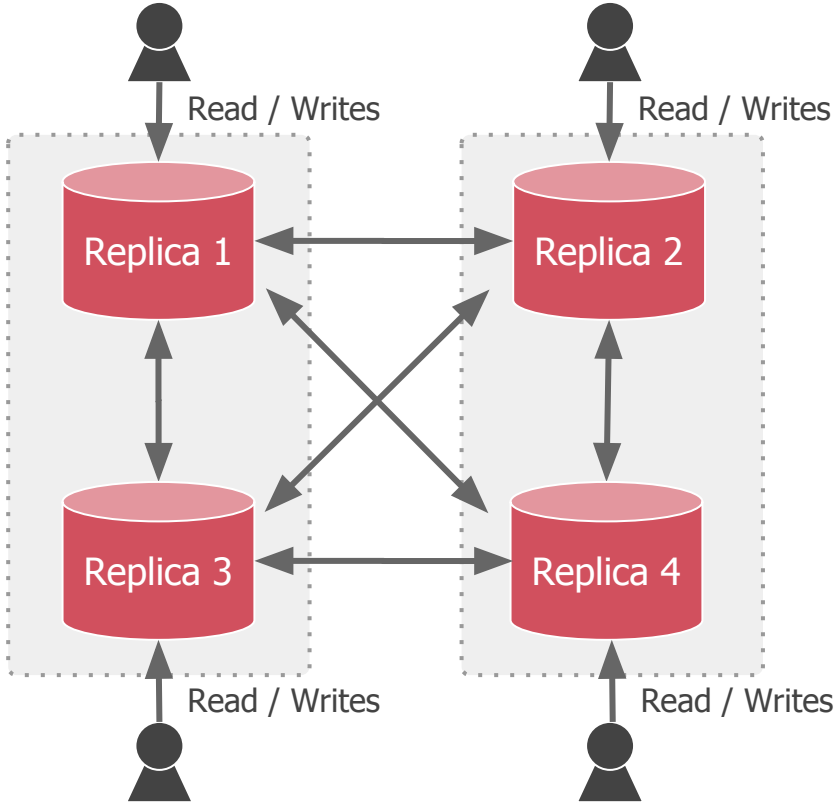

Particionamiento | Motivaciones

Distintos puntos de contacto con la estrategia de **Replicación:**

- *Performance*:
  - Velocidades de escritura
  - Velocidades de lectura
- Conflictos:
  - Evitar colisiones y/o resolución de conflictos
- Redundancia:
  - Permite recuperación frente a fallos

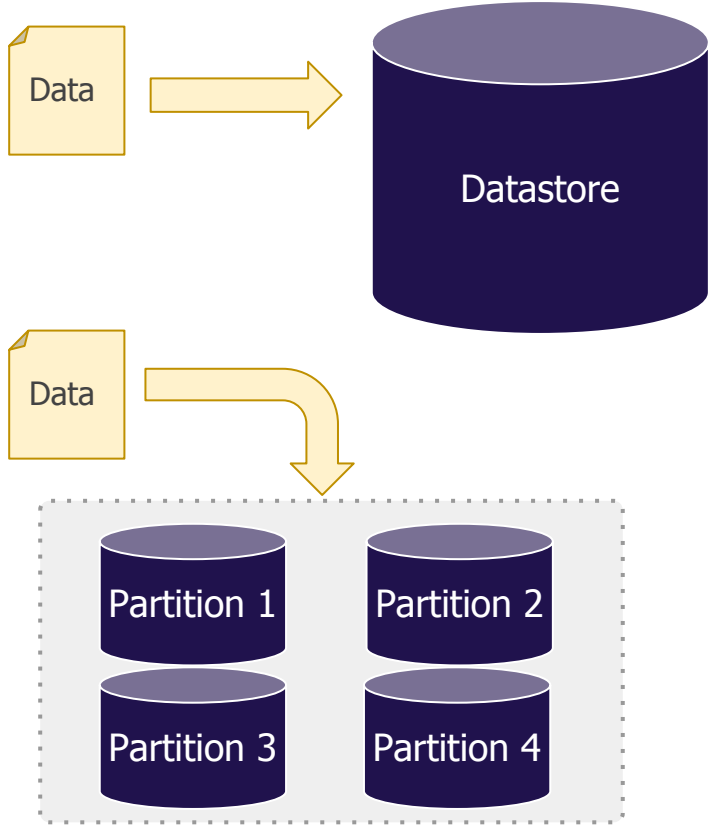

Particionamiento | Horizontal

- La información se segrega de a registros entre cada partición.
- El registro se encuentra en UNA partición a la vez.

date_id	product_id	quantity	price
20100101	100	2	200.00
20100101	101	1	400.00
20100102	100	3	300.00
20100102	103	2	100.00
20100102	103	10	500.00

date_id	product_id	quantity	price
20100101	100	2	200.00
20100101	101	1	400.00

date_id	product_id	quantity	price
20100102	100	3	300.00
20100102	103	2	100.00
20100102	103	10	500.00

Particionamiento | Vertical

- La información se segrega respecto de sus atributos/dimensiones/campos entre cada partición.
- El registro se encuentra en TODAS las particiones.

date_id	product_id	qty	price	disc
20100101	100	2	200.00	NULL
20100101	101	1	400.00	50.00
20100102	100	3	300.00	NULL
20100102	103	2	100.00	NULL
20100102	103	10	500.00	NULL

date_id	product_id	disc
	100	NULL
	101	50.00
	100	NULL
	103	NULL
	103	NULL

date_id	product_id	qty	price
20100101	100	2	200.00
20100101	101	1	400.00
20100102	100	3	300.00
20100102	103	2	100.00
20100102	103	10	500.00

Particionamiento | Función de Partición

- Por *Key-Value*
- Por *Key-Range*
- Por *Hash-of-Key*
- Mixtos:
  - Generar N *shards* por cada *key*
  - Partición por claves secundarias

Particionamiento | Enrutamiento

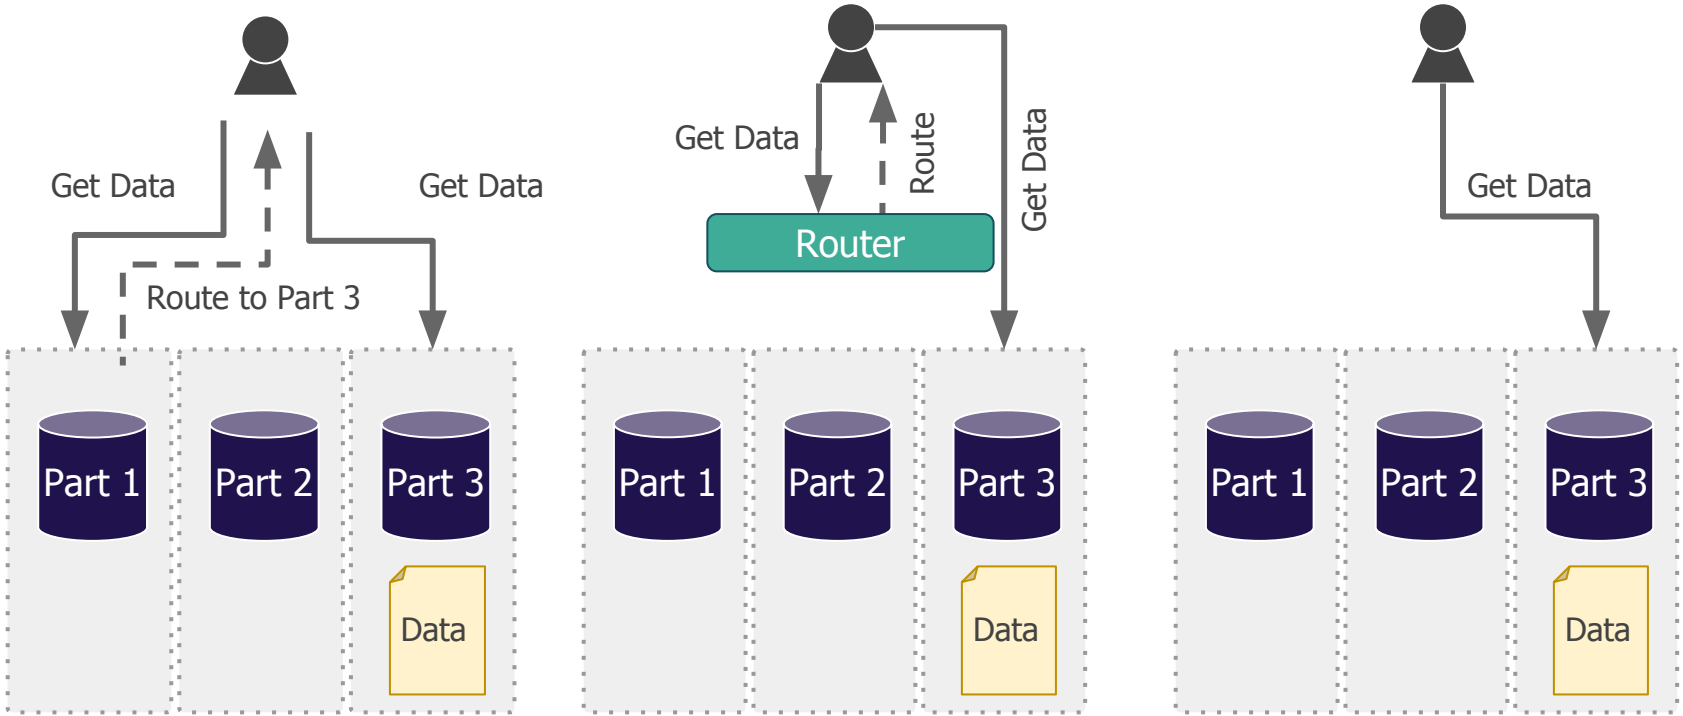

Agenda

- Datos en Sistemas de Gran Escala
- Partición y Replicación
- **Distributed Shared Memory (DSM)**
- Distributed File Systems (DFS)
- Big Table

Distributed Shared Memory (DSM)

Objetivo

- Brindar la *ilusión* de una memoria compartida centralizada

Ventajas

- Muy intuitivo para el desarrollo de sistemas distribuidos: Los algoritmos no distribuidos pueden ser traducidos fácilmente
- Información compartida entre nodos sin que requieran conocerse

Desventajas

- Desalienta la distribución, genera latencia, cuello de botella y punto único de falla (arquitectura cliente-servidor)

DSM | Enfoque *Naive*

- La información es almacenada en memoria por el servidor
- Los clientes acceden mediante requests a escribir o leer las páginas
- El servidor puede garantizar la consistencia muy fácilmente serializando los requests
- Muy baja *performance* para para las aplicaciones cliente

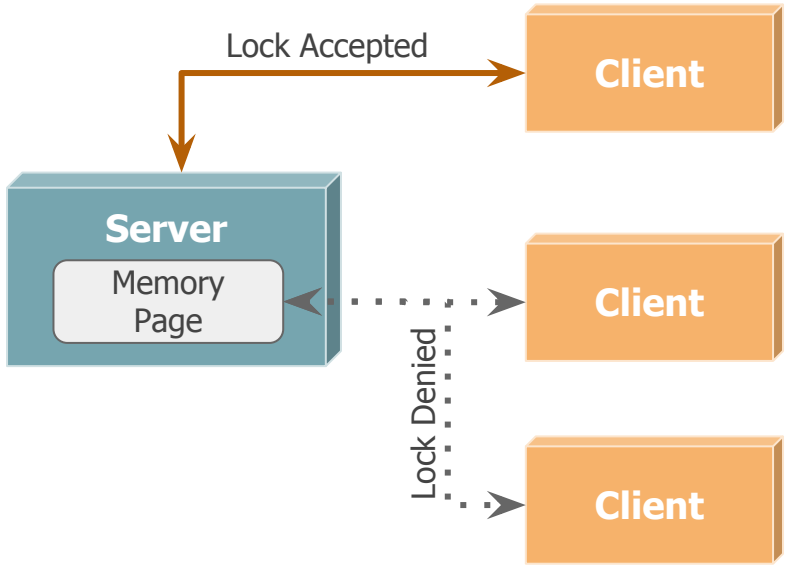

DSM | Migración de *Memory Pages*

- La información es almacenada en memoria por el servidor y delegada en los clientes
- Los clientes pueden optimizar la localidad de acceso pidiendo una *memory page* prestada
- Otros clientes puede pedir la misma página y quedar bloqueados, salvo que se permita una sub-delegación
- Garantiza consistencia. No se accede concurrentemente a las páginas

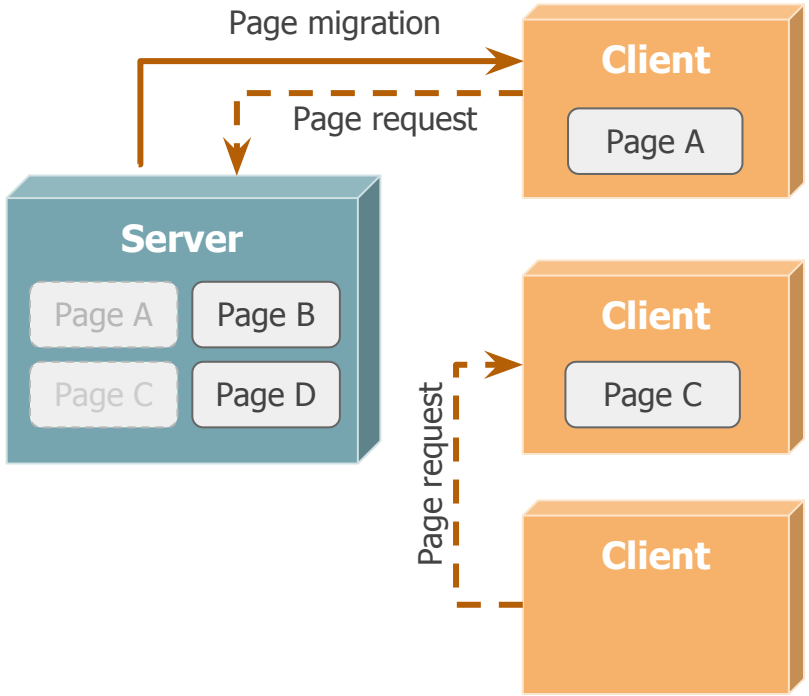

DSM | Replicación de *Memory Pages* (solo lectura)

- Favorece escenarios con muchas lecturas y pocas escrituras
- Las escrituras son coordinadas por el servidor
- Las lecturas implican una replicación de la página en modo *read-only*
- El servidor invalida las réplicas frente a cambios

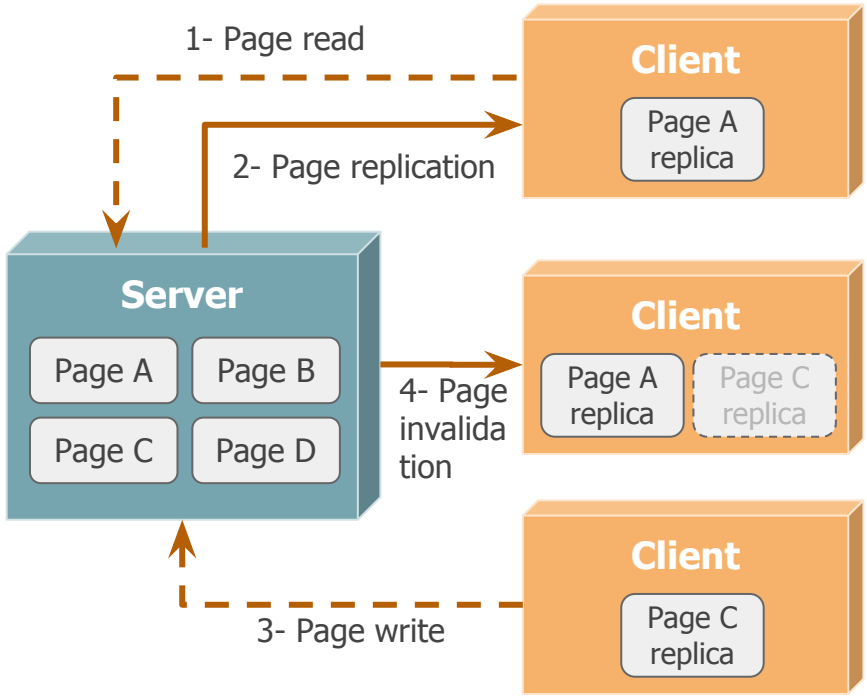

DSM | Replicación de *Memory Pages* (lectura-escritura)

- El servidor mantiene las páginas de memoria hasta que los clientes las requieren
- Los clientes toman control total de las réplicas
- El servidor se transforma en un secuenciador de las operaciones
- El servidor aplica también los cambios ante caídas de los clientes

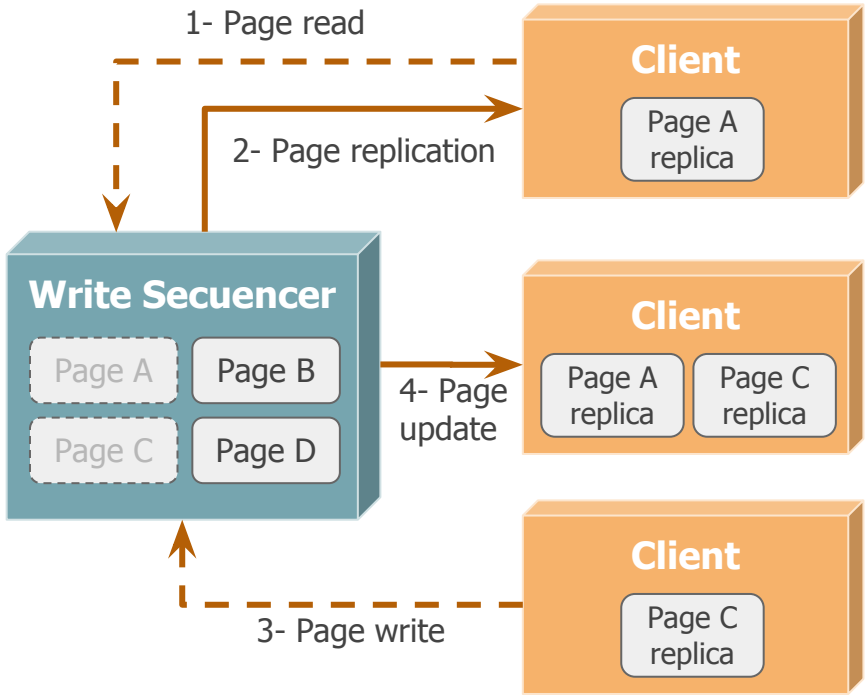

Agenda

- Datos en Sistemas de Gran Escala
- Partición y Replicación
- Distributed Shared Memory (DSM)
- **Distributed File Systems (DFS)**
- Big Table

Distributed File Systems (DFS) | Motivaciones

- Compartir archivos en redes locales e intranets
- Poseer un esquema centralizado de información persistente
  - Control de Backups
  - Control de acceso y monitoreo
- Optimización de recursos por la concentración:
  - Discos de mayor capacidad permitían economizar
  - El costo de administración se reduce

DFS | Factores de Diseño

- **Transparencia a los clientes:**
  - Acceso: obtención de los recursos con credenciales usuales
  - Localización: operación de los archivos como si fueran locales
  - Movilidad: el movimiento interno de archivos no debe ser percibido
  - Performance y Escala: las optimizaciones no deben afectar al cliente
- **Concurrencia:** el acceso concurrente no debe requerir operaciones particulares al cliente
- **Heterogeneidad de Hardware:** adaptación automática a diferentes HWs
- **Tolerancia a Fallos:** capacidad de ocultar o minimizar los fallos (permitir operaciones como *at-least-once* o *at-most-once)*

Caso de Estudio | Network File System (NFS)

- Diseñado para ser independiente de plataformas (pero desarrollado sobre UNIX)
- Primera versión en 1984 por Sun Microsystems
- Requiere una nueva abstracción en el kernel: Virtual File System
- Arquitectura de cliente-servidor utilizando RPC sobre TCP o UDP
- Las aplicaciones utilizan el VFS para acceder a los archivos, lo que requiere una invocación remota
- Los servidores proveen operaciones idénticas a las requeridas por Posix:
  - Soporta ser montado como una unidad virtual

NFS | Arquitectura

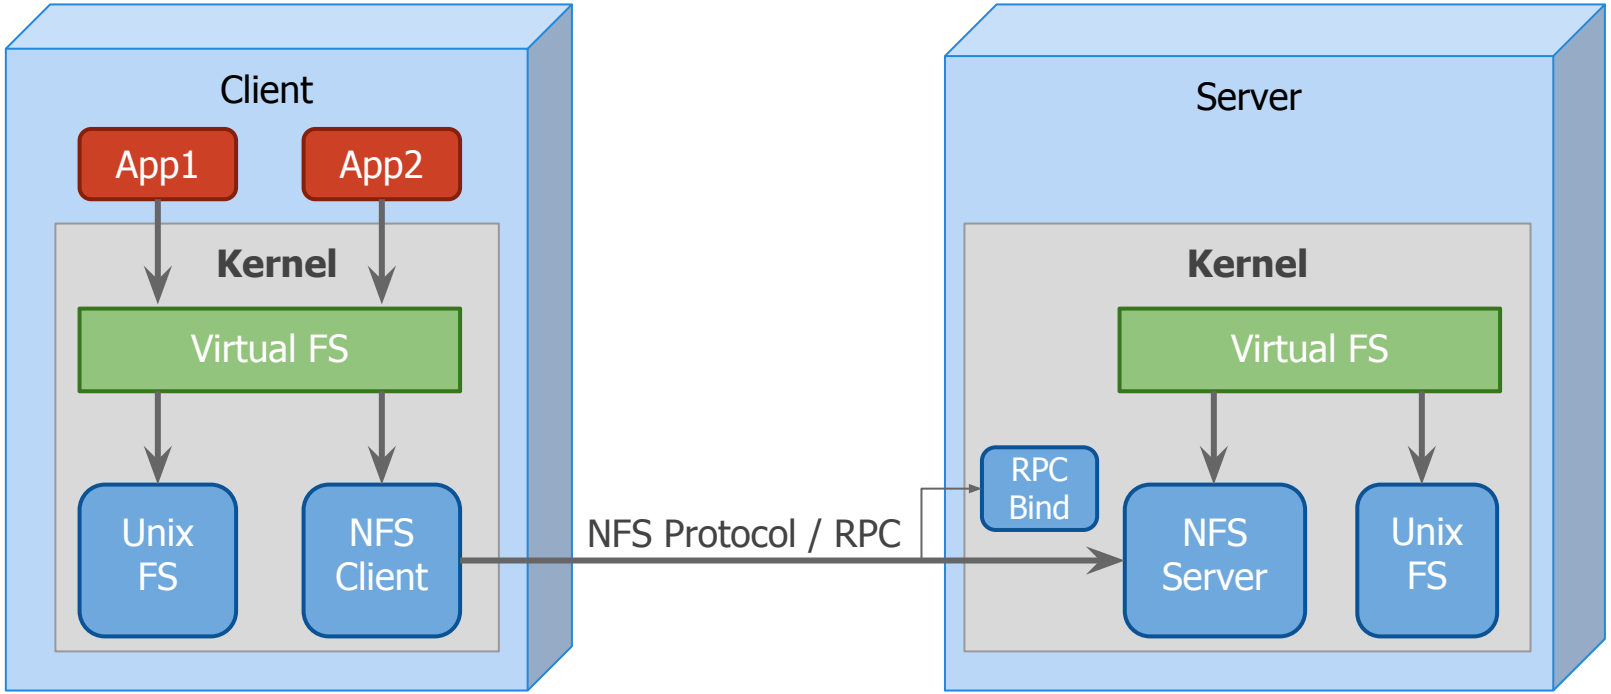

NFS | Instalación Servidor-Cliente

Server

```
apt-get install nfs-kernel-server

vim /etc/idmapd.conf

    ...

    [Translation]
    Method = nsswitch

    ...

vim /etc/exports

    /export 192.168.1.0/24 (...)
```

Client

```
apt-get install nfs-common

mount -t nfs -o proto=tcp,port=2049
        <nfs-server-IP>:/ /mnt
```

Caso de Estudio | Hadoop DFS (HDFS)

- Sistema de archivos distribuido diseñado para utilizar hardware de bajo costo
- Implementación de Apache basada en el diseño de Google File System (GFS)
- No soporta POSIX por lo que se lo considera un Data Storage en lugar de FS
- Base del ecosistema de tecnologías Hadoop para procesamiento distribuido.

HDFS | Factores de Diseño

- **Tolerancia a Fallos:** Los fallos de HW son normales. Es más económico adaptarse que defenderse
- **Volumen y Latencia:** Favorece las operaciones de *streaming* y los archivos volumétricos frente operaciones de usuarios finales de baja latencia
- **Portabilidad:** Preparado para ser utilizado en hardware de bajo costo. Utiliza TCP entre servidores y RPC con clientes
- **Performance:** Favorece operaciones de lectura. Política de *write-once-read-many*

"Moving Computation is Cheaper than Moving Data"

HDFS | Arquitectura

- Arquitectura maestro-esclavo
- **Namenode:** Contiene la información de metadata de archivo. Coordina a los Datanodes
- **Datanodes:** Almacena los datos de archivo.
- Los clientes consultan al Namenode por el 'File system' y ubicación de los datos.
- Los clientes se comunican luego con Datanodes para obtener la información

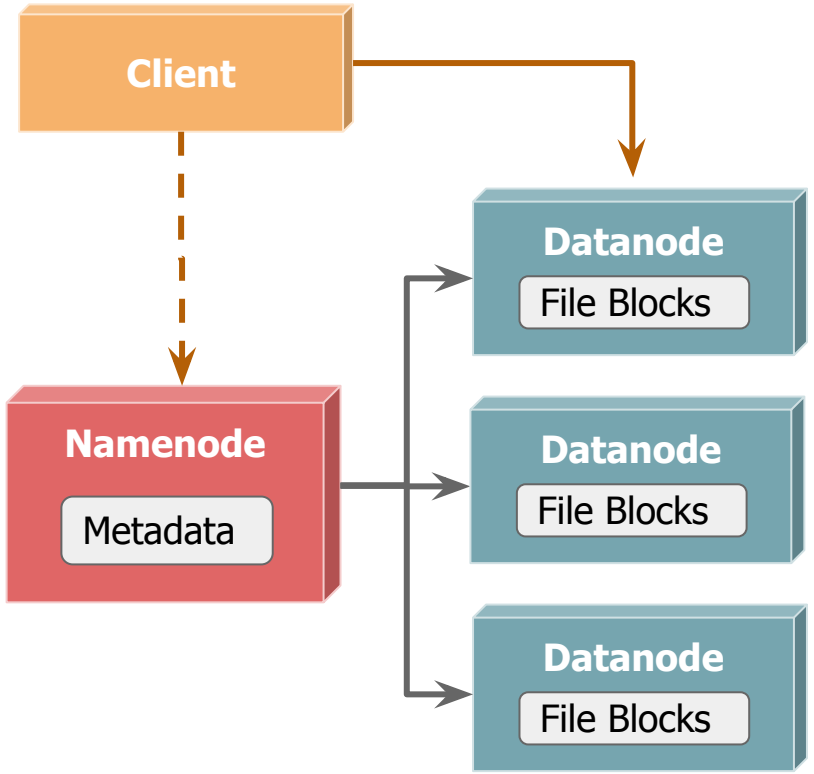

HDFS | Almacenamiento de Datos

- Los archivos se particionan en bloques de 128MB
- Los bloques son replicados en distintos Datanodes
- El Namenode mantiene el listado de Datanodes para un archivo
- La metadata es mantenida en memoria para optimizar acceso, con un log de transacciones
- El cluster de Datanodes permite re-balanceo de bloques

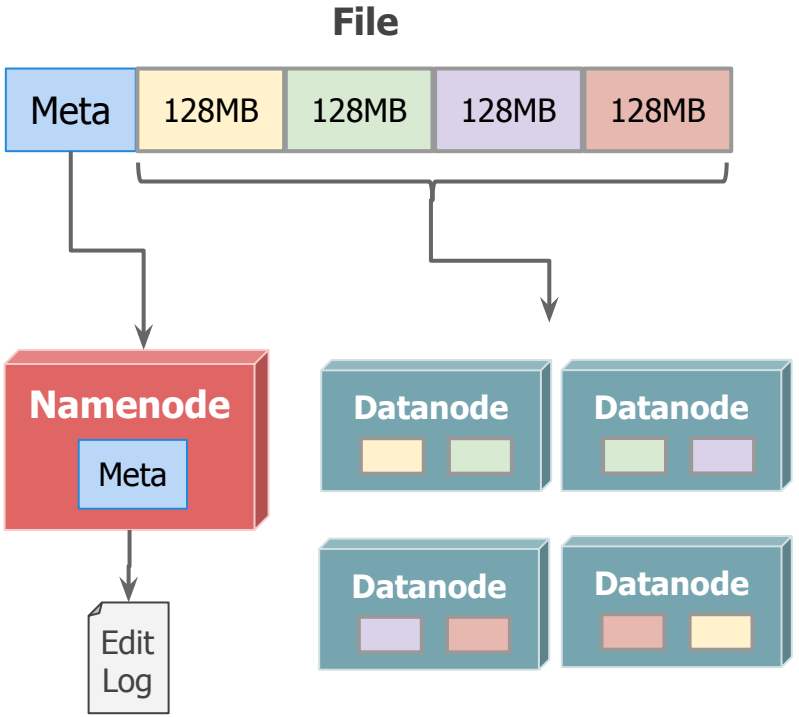

HDFS | Acceso a Datos

- El Namenode favorece el principio de localidad de datos para el cliente
- El cliente recibe listado de Datanodes para cada bloque y sus réplicas
- Se intenta obtener los bloques desde el mismo rack.
- Si no es posible, desde el mismo datacenter

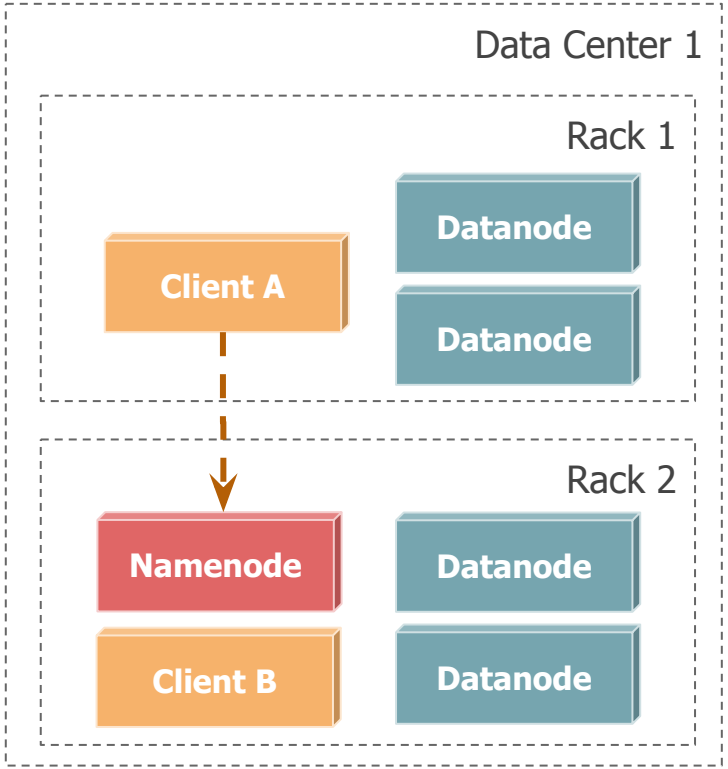

Agenda

- Datos en Sistemas de Gran Escala
- Partición y Replicación
- Distributed Shared Memory (DSM)
- Distributed File Systems (DFS)
- **Big Table**

BigTable | Características

Claves, datos y columnas

- Solo almacena pares clave-datos.
- Los datos son en realidad un conjunto de valores (o columnas).
- Al tratarse de conjuntos dispersos (*sparse*), los valores no se almacenan en un orden definido sino que conocen su 'column family'.

Tablets

- Conjunto de filas consecutivas de acuerdo a la clave.
- Unidad de balanceo de BigTable. Permite escalar el sistema.

BigTable | Jerarquía

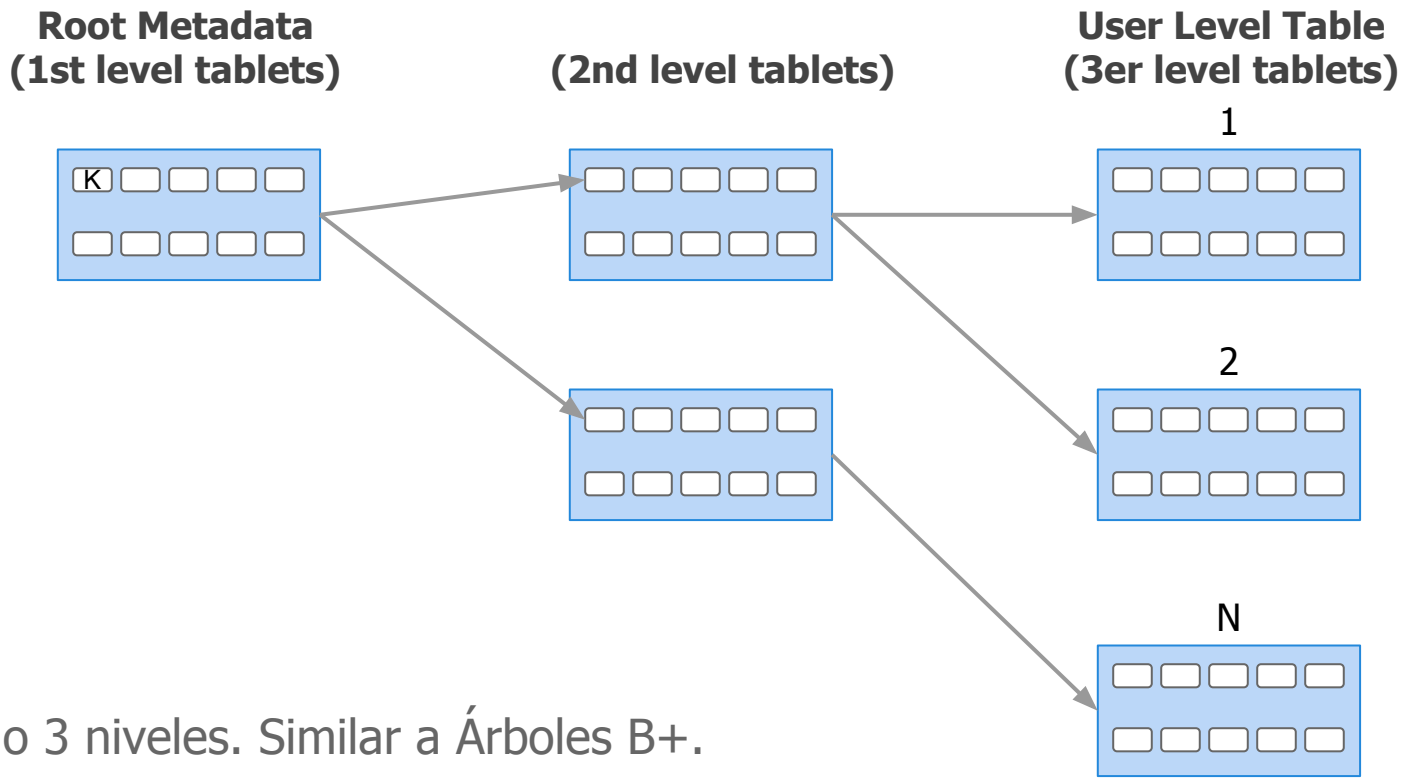

Solo 3 niveles. Similar a Árboles B+.

BigTable | Arquitectura

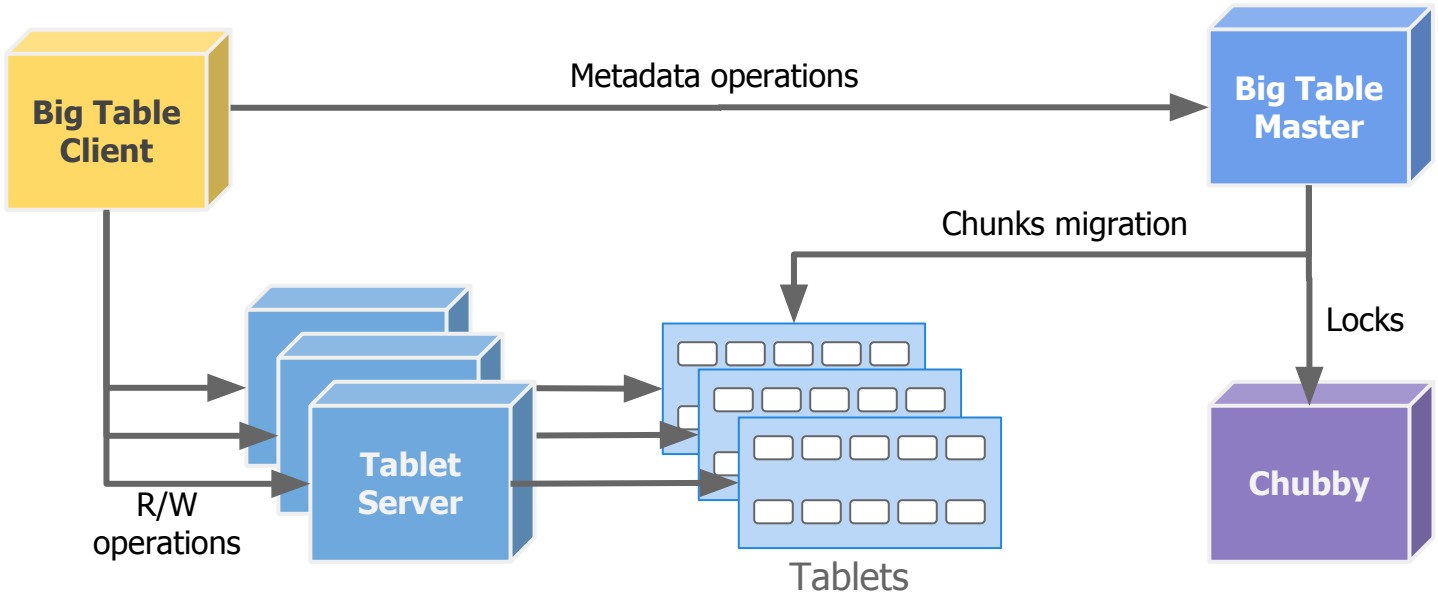

BigTable | Balanceo de Tareas

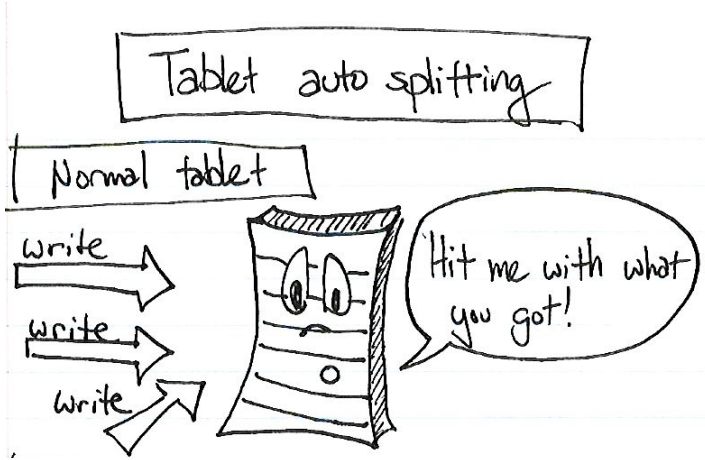

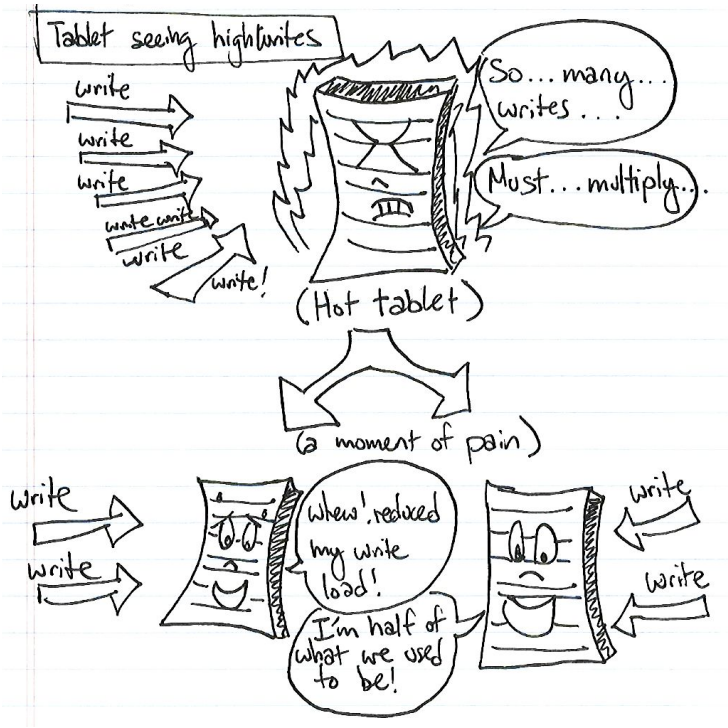

Source: https://ikaisavys.com/2011/01/25/app-engine-datastore-tip-monotonically-increasing-values-are-bad/, Ikai Lan

BigTable | División de Tablets Exitoso

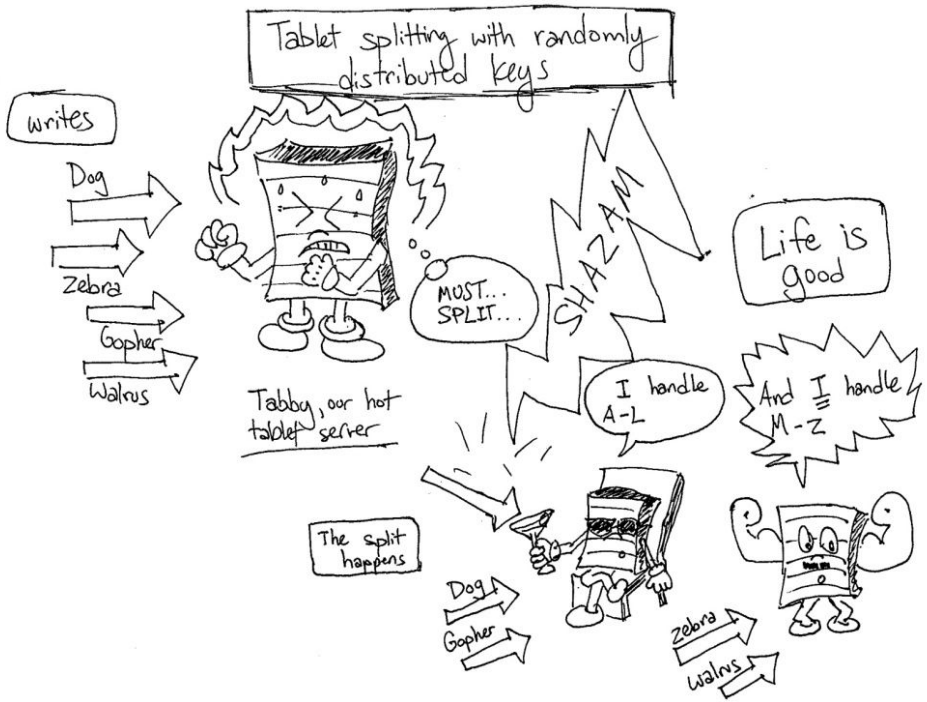

Source: https://ikaisavs.com/2011/01/25/app-engine-datastore-tip-monotonically-increasing-values-are-bad/, Ikai Lan

BigTable | División de Tablets No Exitoso

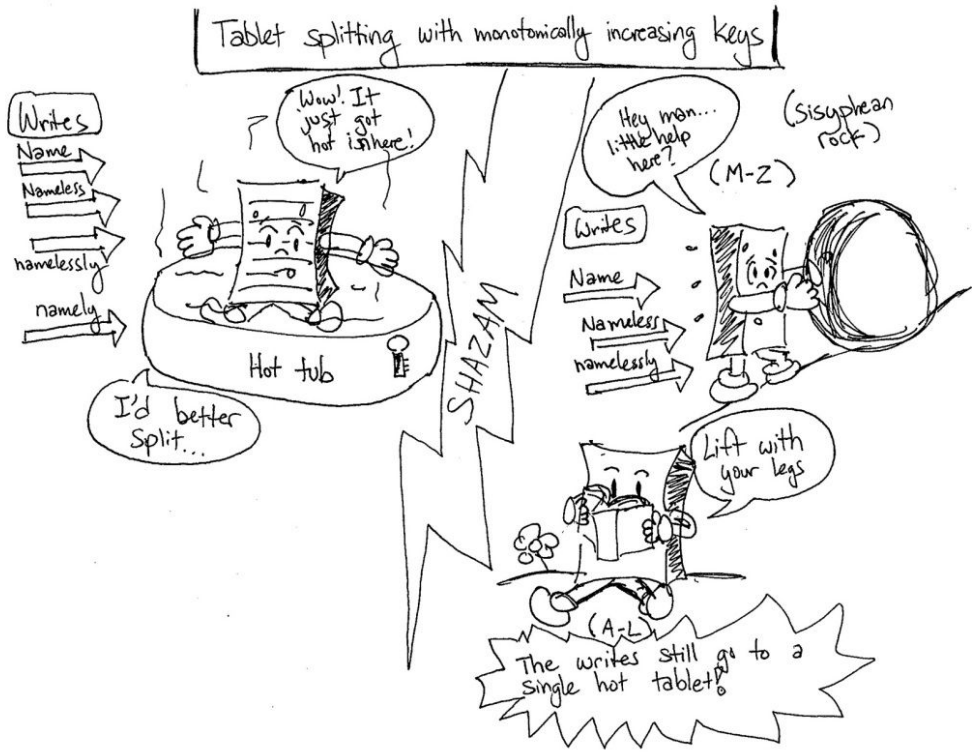

Source: https://ikaisavs.com/2011/01/25/app-engine-datastore-tip-monotonically-increasing-values-are-bad/, Ikai Lan

Bibliografía

- Martin Kleppmann, Designing Data-Intensive Applications, 2017
  - Cap. 1 - Reliable, Scalable, and Maintainable Applications
  - Cap. 5 - Replication
  - Cap. 6 - Partitioning
- P. Verissimo, L. Rodriguez: Distributed Systems for Systems Architects, Kluwer Academic Publishers, 2001.
  - Cap. 3.8 - Distributed Shared Memory
- The Apache Group, HDFS Architecture, 2019, v3.2.1
  - https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html
- Chang, Dean, et al, Bigtable: A Distributed Storage System for Structured Data, 2006