Sistemas Distribuidos I
(75.74)

Algoritmos de Consenso

Elección de Líder. Generales Bizantinos. Paxos.

Docentes

- Pablo D. Roca
- Ezequiel Torres Feyuk
- Guido Albarello
- Ana Czarnitzki
- Cristian Raña

Agenda

- **Elección de Líder**
- Consenso
- Generales Bizantinos
- Paxos

Elección de Líder | Introducción

- **Objetivo**
  - Elegir a un proceso en un grupo para que desempeñe un rol particular
  - Permitir reelecciones en caso de que proceso líder decida darse de baja
  - Permitir reelecciones en caso de que proceso líder se encuentre caído
- **Características**
  - Cualquier proceso puede comenzar una nueva elección de líder
  - En ningún momento puede haber más de un líder
  - El resultado de la elección de un nuevo líder debe ser **única y repetible**

Elección de Líder | Propiedades

- Cada proceso debe tener un identificador único
- Todos los procesos poseen un array que indica el estado del algoritmo de elección de Líder
- Estados posibles: *Identificador (P), indefinido (@)*
  - *Indefinido (@)* es el estado inicial que posee un proceso P_i al comenzar a participar del algoritmo de elección de líder

- **Safety**
  - Un proceso participante P_i posee el estado $elected_i = P$ *o* $elected_i = @$
- **Liveness**
  - Todos los procesos participan de la elección de líder y bien terminan con un estado $elected_i != @$ *o comienzan una nueva elección de líder*

Elección de Líder | Algoritmo del anillo

- **Condiciones Iniciales**
  - Cada proceso se comunica solamente con su vecino
  - Mensaje son enviados siempre en la misma dirección (e.g. sentido horario)
  - Al comienzo del algoritmo, todos los procesos son marcados como *no participantes*

- **Inicio de la elección**
  - Algún proceso P_i se marca como *participando* y envía un mensaje en sentido horario indicando que él es el líder

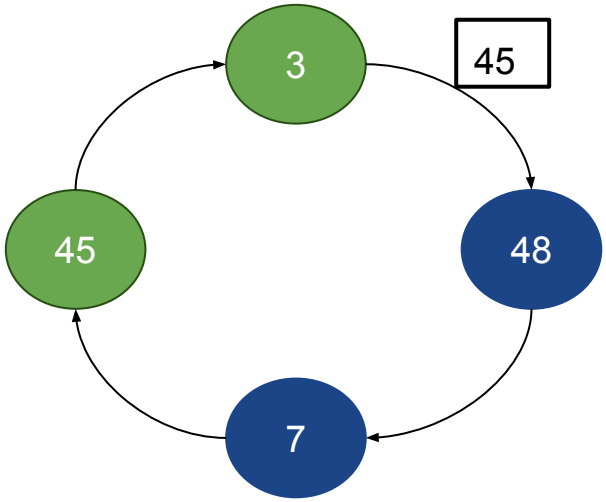

Elección de Líder | Algoritmo del anillo

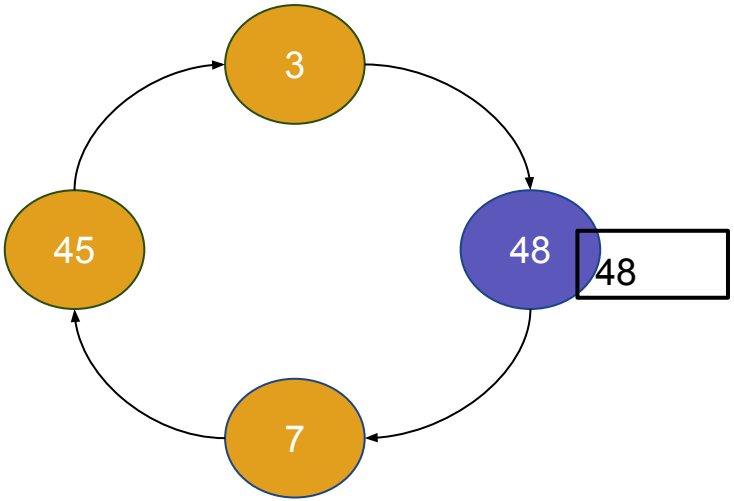

Ronda1: 1
Ronda2: 4
Ronda3: 4

Worst case: N=4 => 3N - 1
Best case: 2N + 1

- **Proceso P_j recibe mensaje de elección de líder y...**
  - Reenvía el mensaje si se encuentra en estado *no participando*
    - Cambia su estado a *participando*
    - Compara el identificador del líder con el suyo y lo reemplaza en caso de que sea mayor
  - Si el proceso se encuentra en estado *participando*
    - *No reenvía el mensaje si el ID recibido es mejor al suyo*
    - *Reenvía el mensaje si el ID recibido es mayor al suyo*
    - Si el identificador recibido es igual al Suyo, entonces **el proceso P_j es el líder!!**

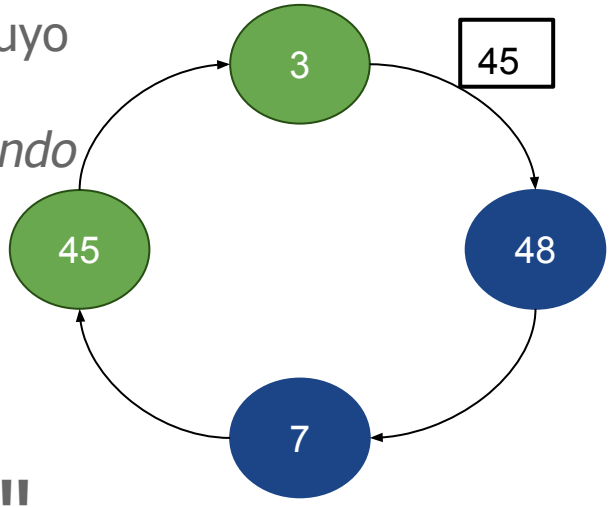

Elección de Líder | Algoritmo del anillo

- **Proceso P_j reconoce que es el líder y…**
  - Se setea como *no participando*
  - Envía un mensaje de **líder elegido**

- ***Proceso P_j* recibe un mensaje de líder elegido y…**
  - Cambia su estado a *no participando*
  - Setea la variable elegido con el identificador del mensaje recibido
  - Retransmite el mensaje siempre el identificador Recibido sea distinto al suyo

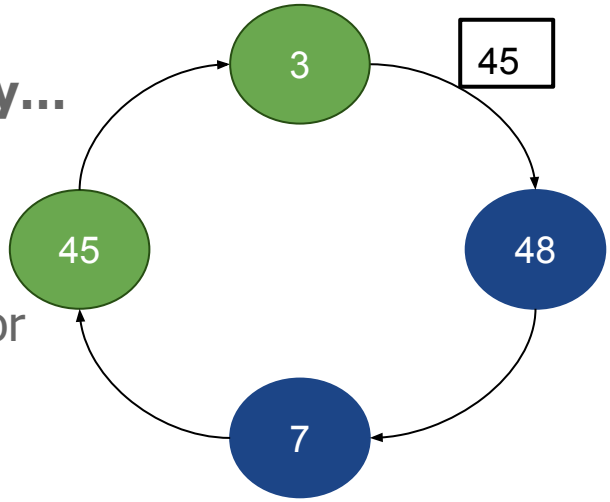

Elección de Líder | Bully Algorithm

- **Hipótesis**
  - Canales de comunicación *reliables*
  - Cualquier proceso puede morir de forma inesperada
    - Uso de timeouts para detectar que un proceso no está respondiendo
  - Todos los procesos pueden comunicarse entre sí
  - Cada proceso conoce el ID asociado a todos los procesos
  - Cada proceso conoce qué procesos **poseen un ID superior al suyo**

Elección de Líder | Bully Algorithm

- **Tipos de Mensajes**
  - Election Message: Mensaje enviado para iniciar una elección de líder
  - Answer Message: ACK de Election Messages
  - Coordinator Message: Contiene información sobre quién fue el proceso líder elegido
- **Sincronismo**
  - Tmax: Tiempo máximo de transmisión
  - Tprocess: Tiempo máximo que proceso tarda en procesar un mensaje
  - **T = 2 * Tmax + Tprocess** (timeout para detectar procesos caídos)

- **Algoritmo (Parte I)**
  - Proceso con mayor ID puede identificarse como leader y mandar un *Coordinator Message* a todos los procesos del sistema
  - Si un proceso detecta que el líder está caído, envía *Election Messages* a procesos que tengan **un ID mayor al suyo**
  - Si un proceso recibe un *Election Message*, responde con un *Answer Message y* **comienza una nueva elección**
  - Si un proceso recibe un *Coordinator Message,* elige al proceso que envió el mensaje como líder
  - Si un proceso que comenzó una elección no recibe *Answer Messages* después de transcurrido tiempo T, **el proceso se autoproclama líder**

- **Algoritmo (Parte II)**
  - Si un proceso caído vuelve a la vida, **comienza una nueva elección de líder**
    - Si este proceso es el que posee mayor ID, será elegido como el nuevo líder
    - Por esta razón este algoritmo es llamado **Bully Algorithm**

Elección de Líder | Bully Algorithm

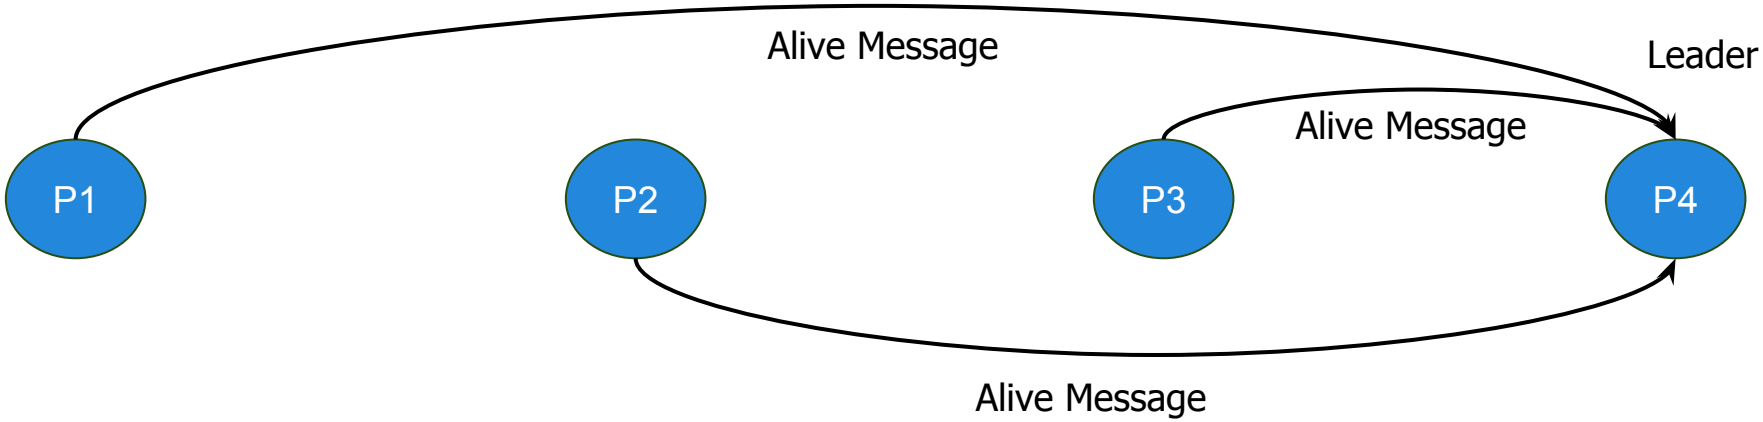

Elección de Líder | Bully Algorithm

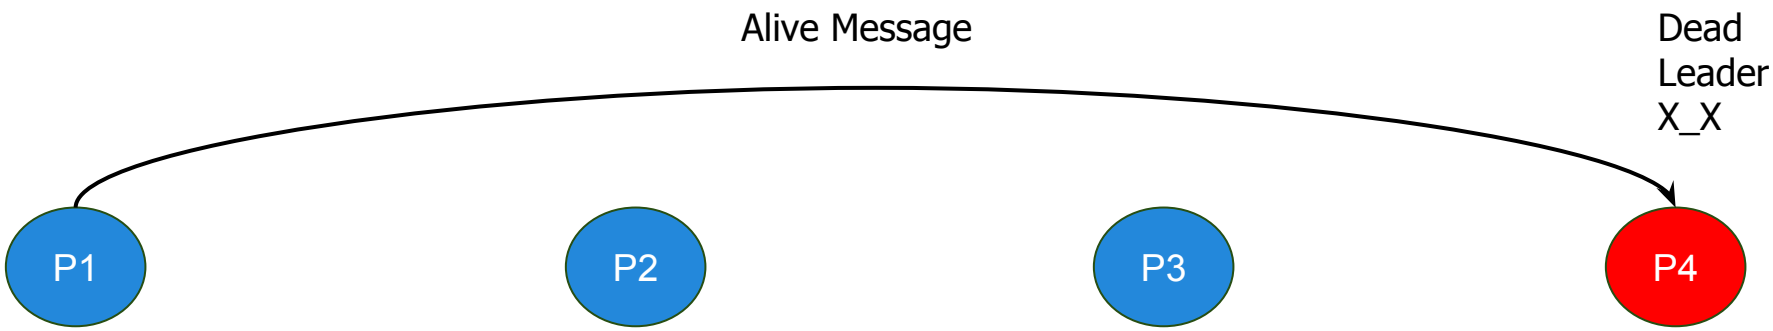

P1 detecta que P4 está caído

Elección de Líder | Bully Algorithm

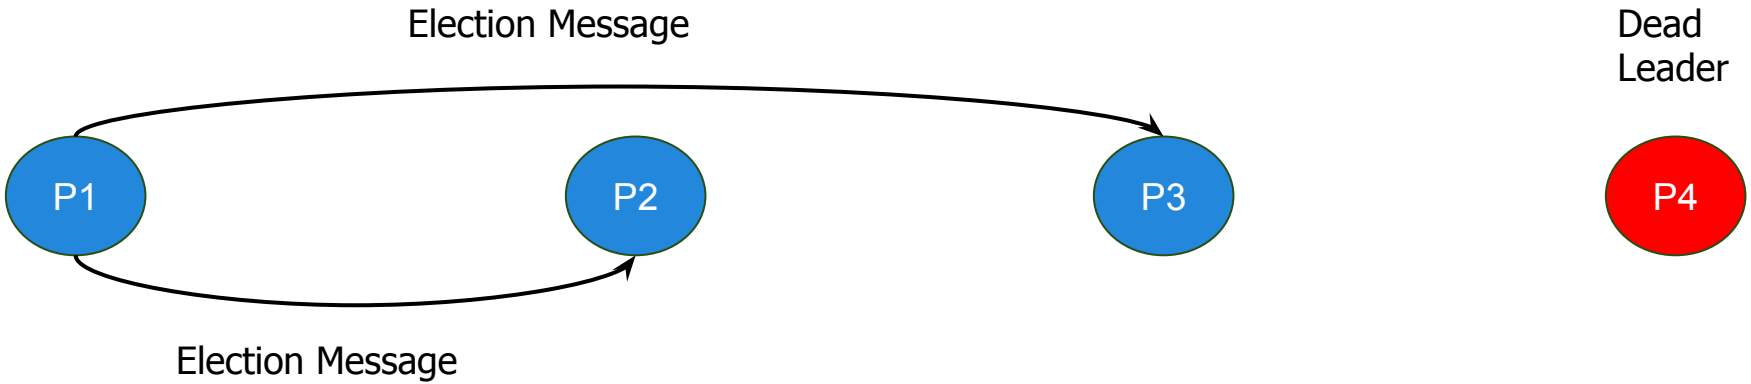

Elección de Líder | Bully Algorithm

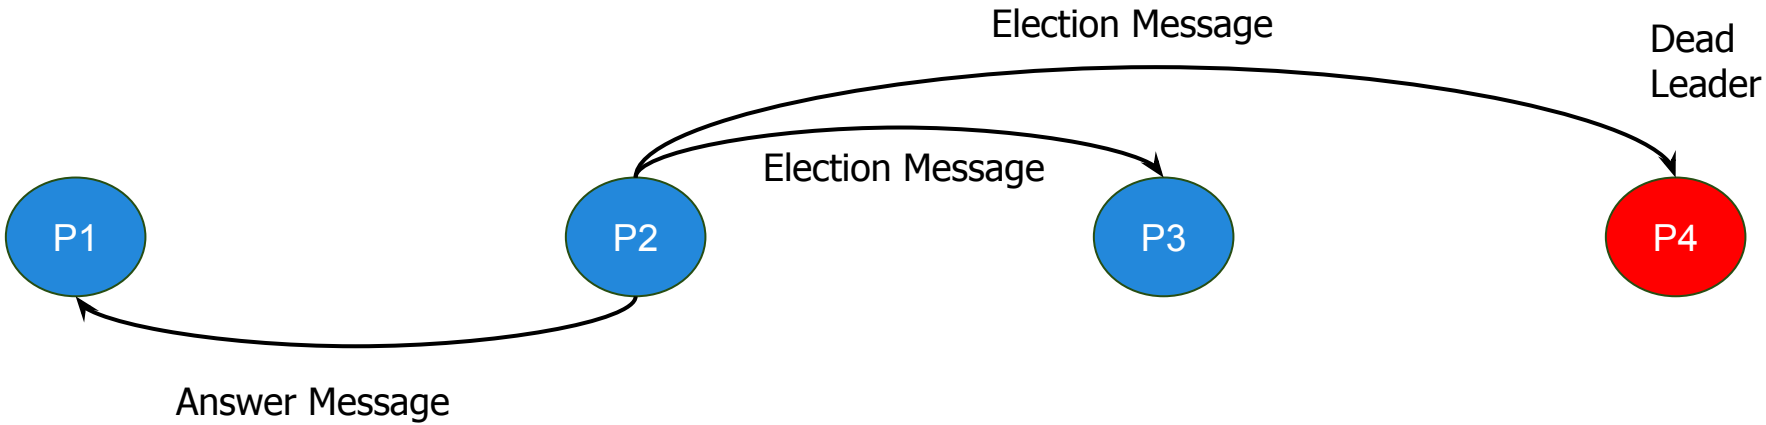

Elección de Líder | Bully Algorithm

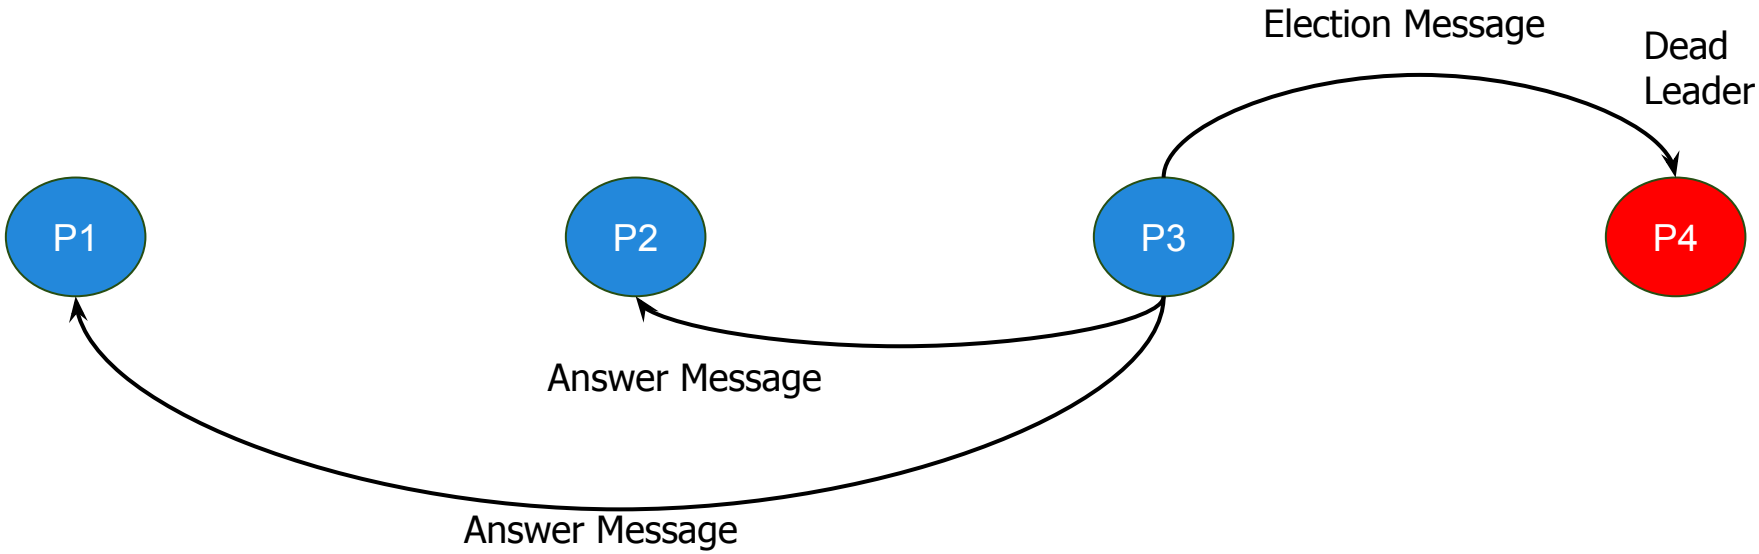

Elección de Líder | Bully Algorithm

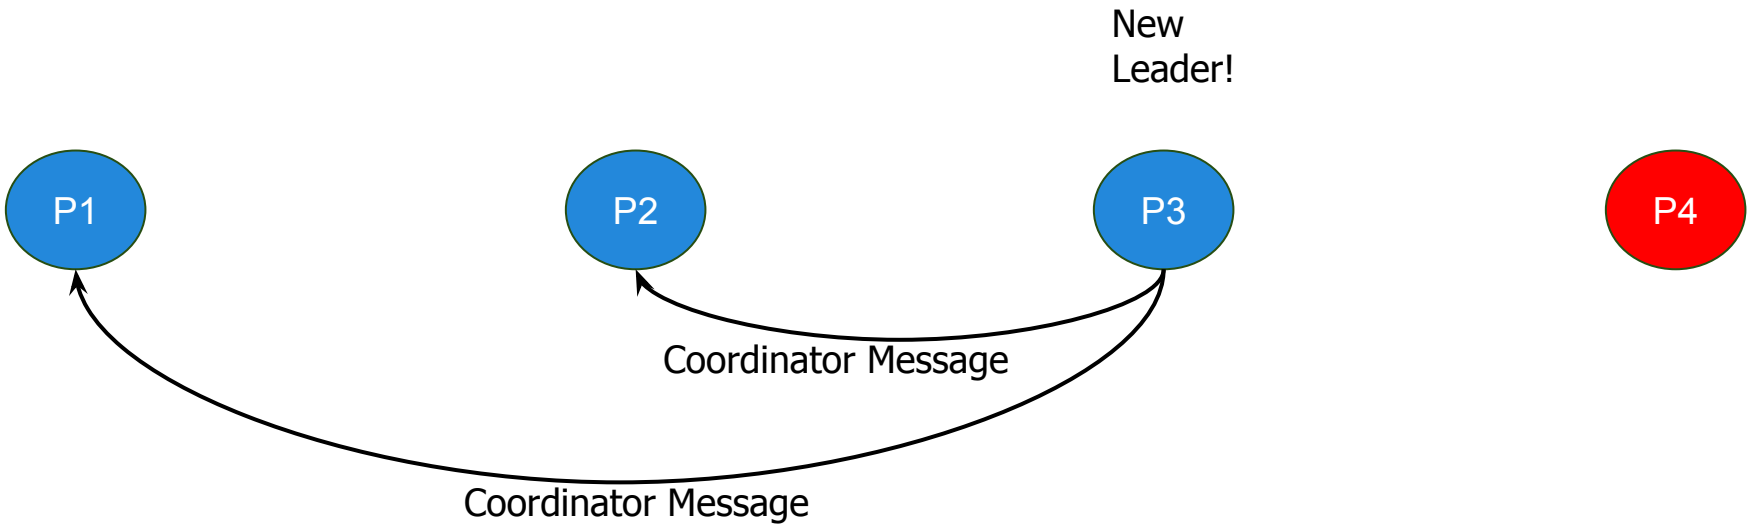

P4 no responde a P3 en T time: se autoproclama lider

Elección de Líder | Bully Algorithm

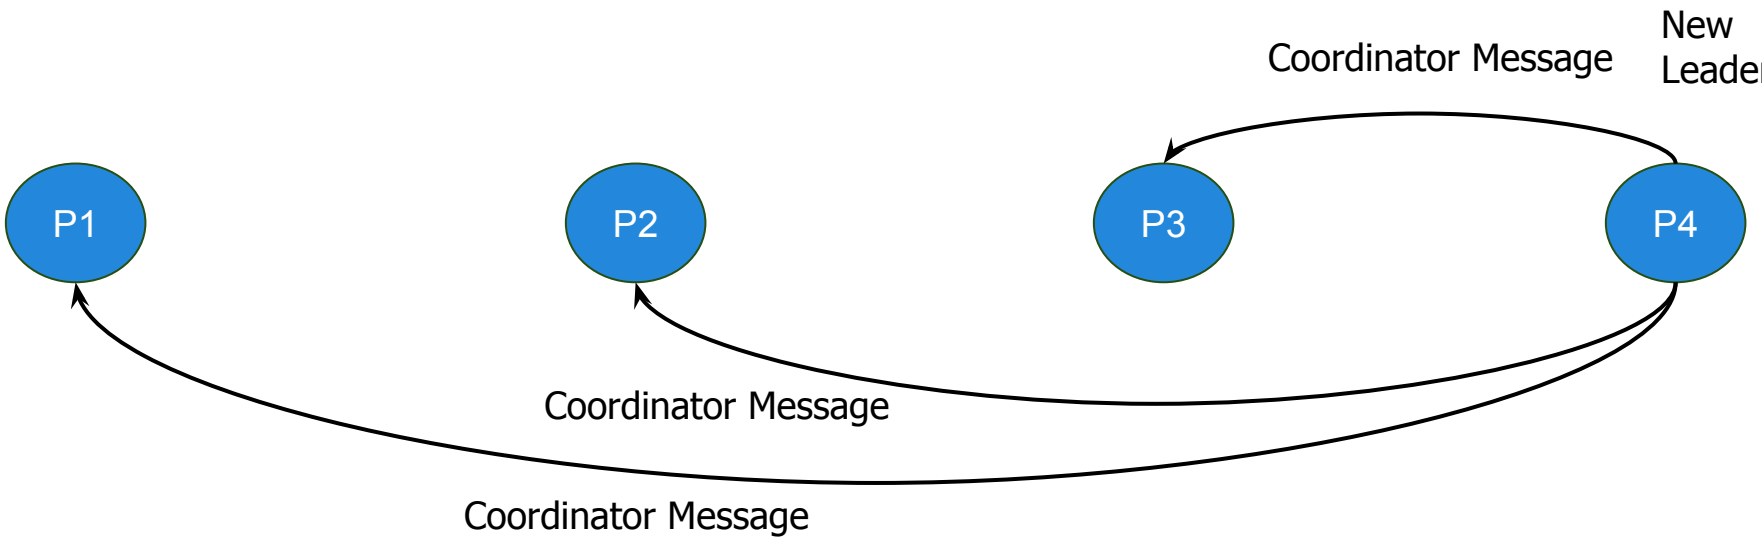

P4 vuelve a la vida: se autoprocralama lider por tener ID más alto

Elección de Líder | Bully Algorithm

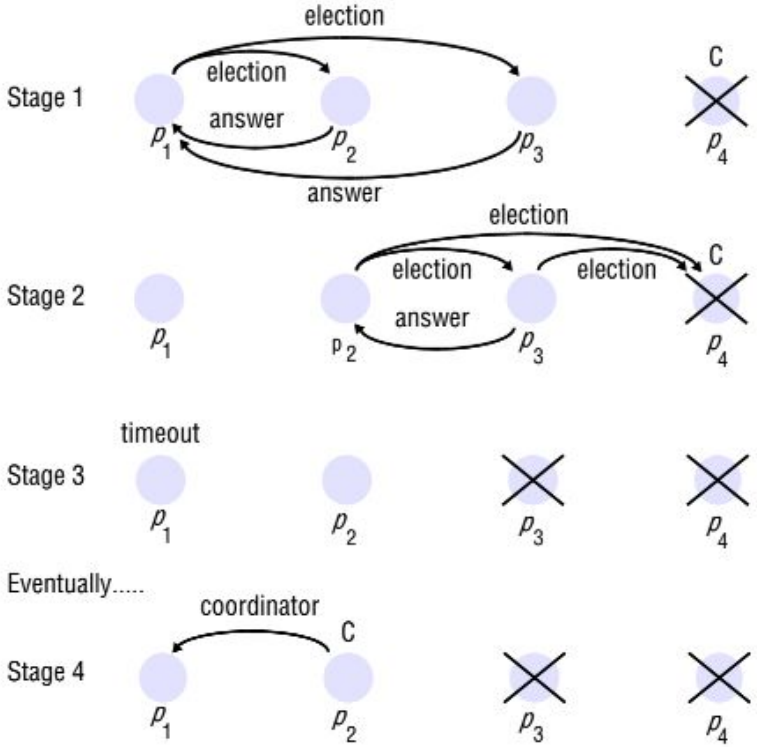

Agenda

- Elección de Líder
- **Consenso**
- Generales Bizantinos
- Paxos

Consenso | *Introducción*

- Dado un conjunto de procesos distribuidos y un punto de decisión, todos los procesos deben acordar en el mismo valor
- **Problema complejo, require acotar variables:**
  - Canales de comunicación son *reliables*
  - Todos los procesos pueden comunicarse entre sí
  - Única falla a considerar es la caída de un proceso
  - Caída de un proceso no puede ocasionar la caída de otro
- Propiedades necesarias de los algoritmos de consenso:
  - *Agreement*
  - *Integrity*
  - *Termination*

- **Definición**
  - Conjuntos de P_i (i= 1...N) procesos desean llegar a un acuerdo
  - Cada proceso comienza en el estado ***undecided***
  - Cada proceso posee una ***decision variable*** d_i (i = 1...N)
  - Cada proceso propone un valor v_i
  - Procesos se comunican entre sí a través de mensajes
  - Luego de haber recibido mensajes de otros procesos, proceso P_i setea su ***decision variable*** d_i y cambia su estado a ***decided***

- **Requerimientos**
  - *Agreement*
    - El valor de la variable ***decided*** es el mismo en todos los procesos correctos
    - Si P_i y P_j son procesos correctos entonces $d_i = d_j$ cuando su estado es ***decided***
  - *Integrity*
    - Si los procesos correctos propusieron el mismo valor v_i, entonces el valor de su ***decision variable*** es la misma
  - *Termination*
    - Eventualmente todos los procesos activos setean su ***decision variable***

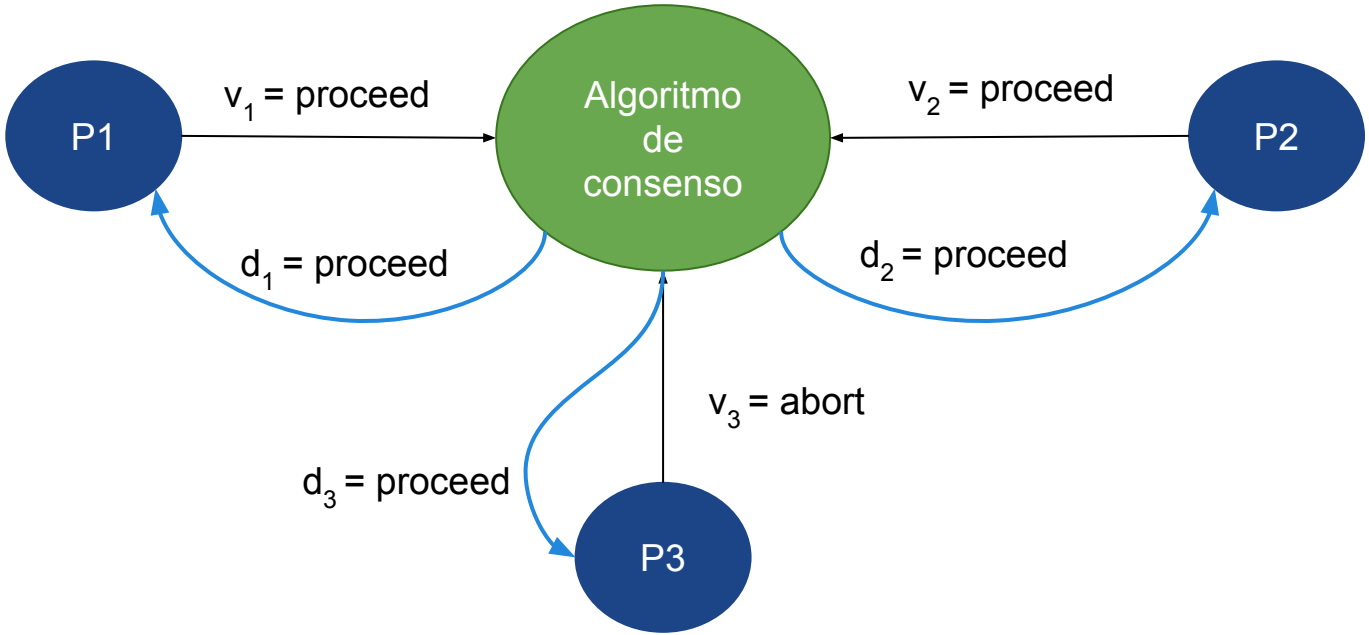
P1
v_1 = proceed
Algoritmo de consenso
v_2 = proceed
P2
d_1 = proceed
d_2 = proceed
v_3 = abort
d_3 = proceed
P3

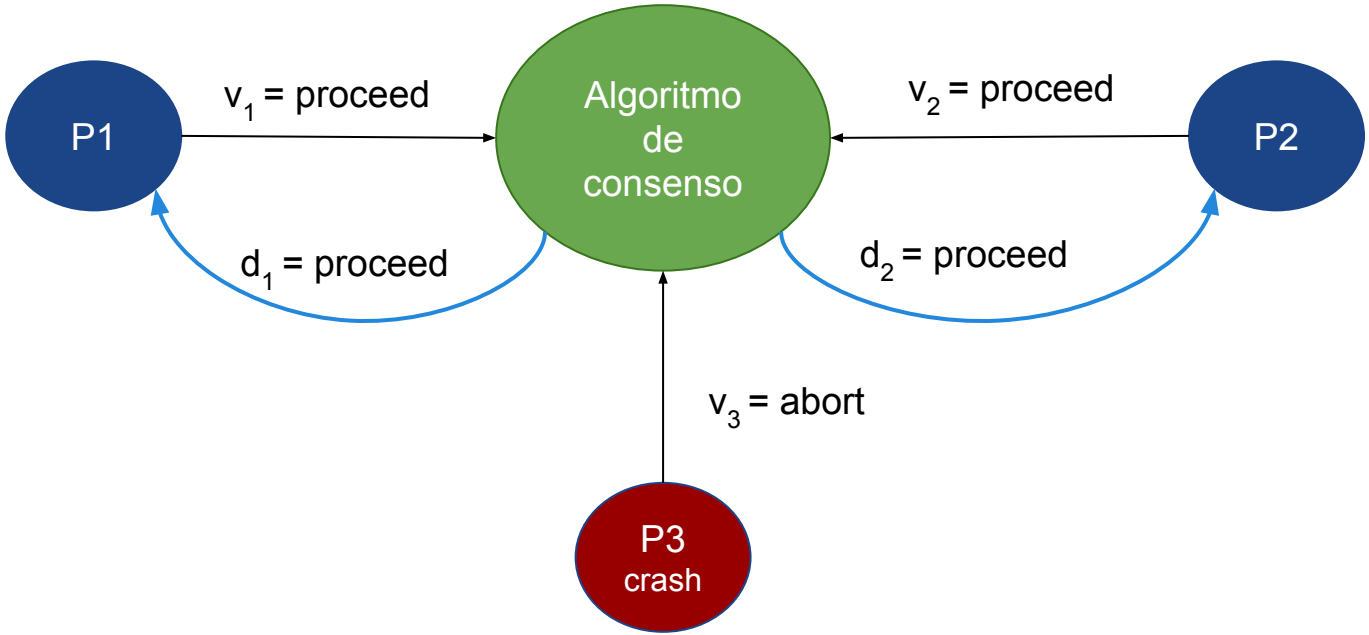
P1
v_1 = proceed
Algoritmo de consenso
v_2 = proceed
P2
d_1 = proceed
d_2 = proceed
v_3 = abort
P3 crash

Consenso | *Algoritmo sincrónico*

```
Init
  Values(i, 0) = {}, Values(i, 1) = { v }

For each round r, 1 < r <= f+1
  broadcast Values(i, r) - Values(i, r-1)
  Values(i, r+1) = Values(i, r)
  While round r still open
    receive Values from j in Values(j, r)
    Values(i, r + 1) = Values(i, r + 1) U Values(j, r)

After f+1 rounds
  decide d = aggregation over Values(i, f+1)
```

Agenda

- Elección de Líder
- Consenso
- **Generales Bizantinos**
- Paxos

Generales Bizantinos | Definición y *Requerimientos*

- **Definición**
  - Tres o más **generales** deben decidir si atacan o se retiran
  - Un **comandante** envía la orden de ataque/retirada
  - **Generales** pueden ser *traicioneros*
    - Le indica a los otros generales que deben atacar si el comandante le indicó que se retiren y viceversa
  - **Comandante** puede ser *traicionero*
    - Envía diferentes órdenes a diferentes generales
  - **Comandante / General** *traicionero* viene a emular a un proceso que posee fallas

- **Requerimientos**
  - *Agreement*
    - El valor de la variable ***decided*** es el mismo en todos los procesos activos
    - Si P_i y P_j son procesos activos entonces $d_i = d_j$ cuando su estado es ***decided***
  - *Integrity*
    - Si el comandante *no es traicionero*, todos los procesos deben setear su ***decision variable*** al valor enviado por el comandante
  - *Termination*
    - Eventualmente todos los procesos activos setean su ***decision variable***

Generales Bizantinos | Imposibilidad N <= 3f

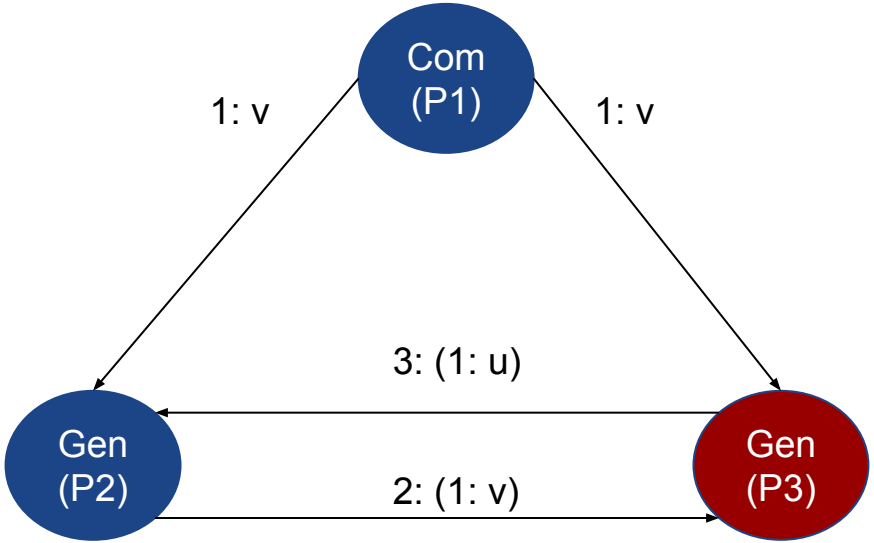

Generales Bizantinos | Imposibilidad N <= 3f

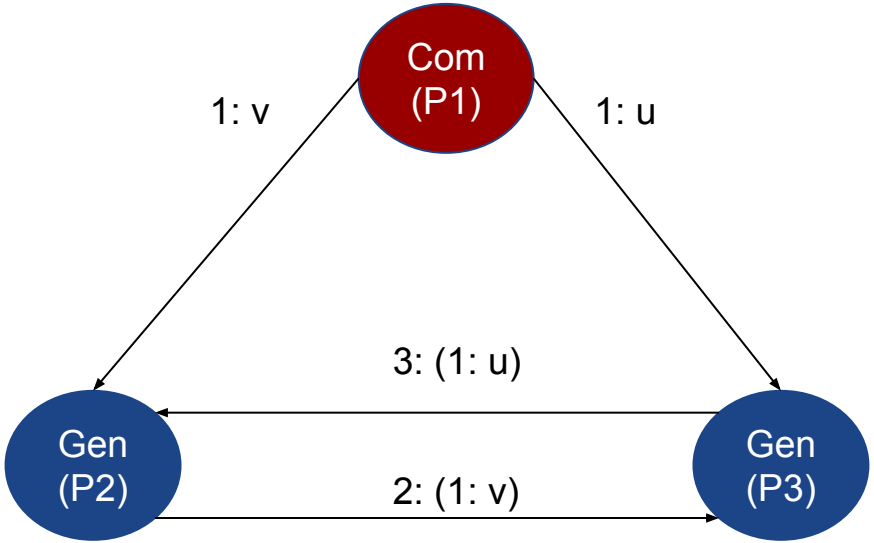

Generales Bizantinos | Solución N >= 3f + 1

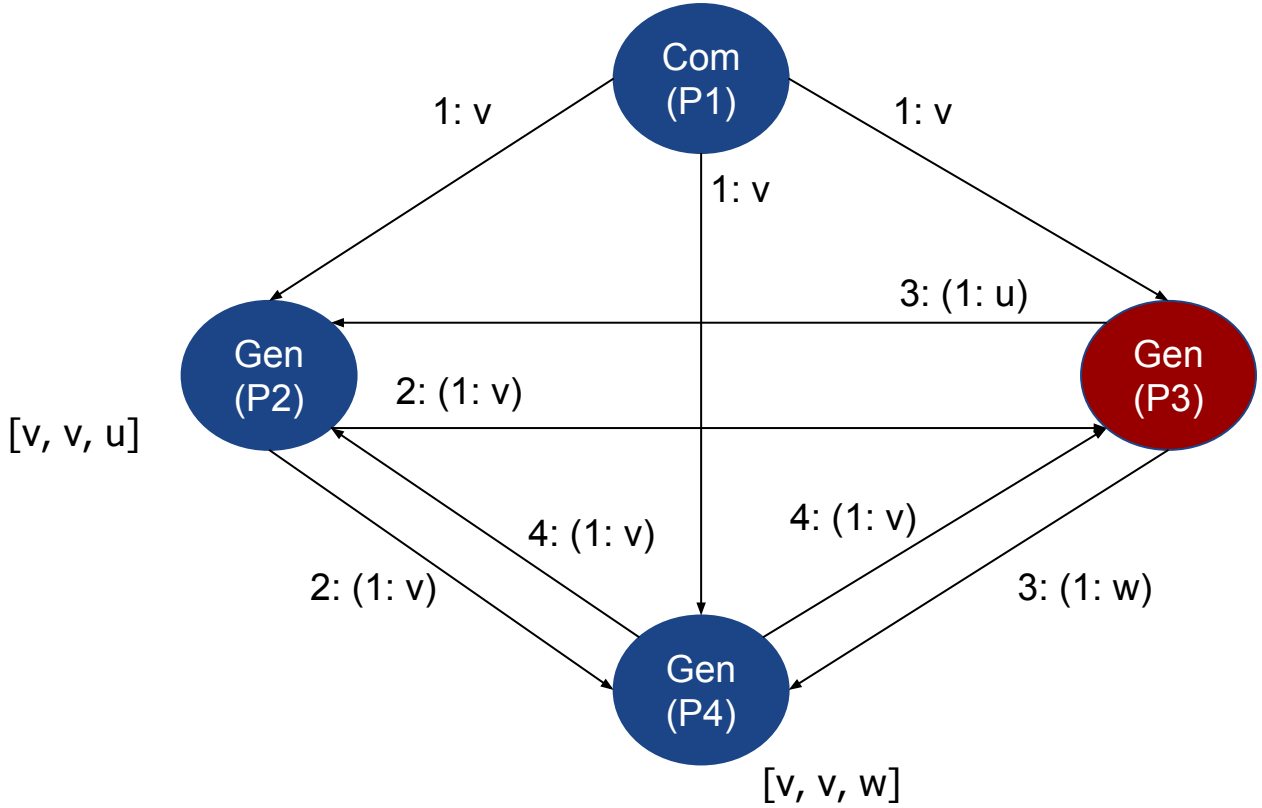

4 >= 3*1 + 1
7 >= 3*2 + 1
10 >= 3*3 +

Generales Bizantinos | Solución N >= 3f + 1

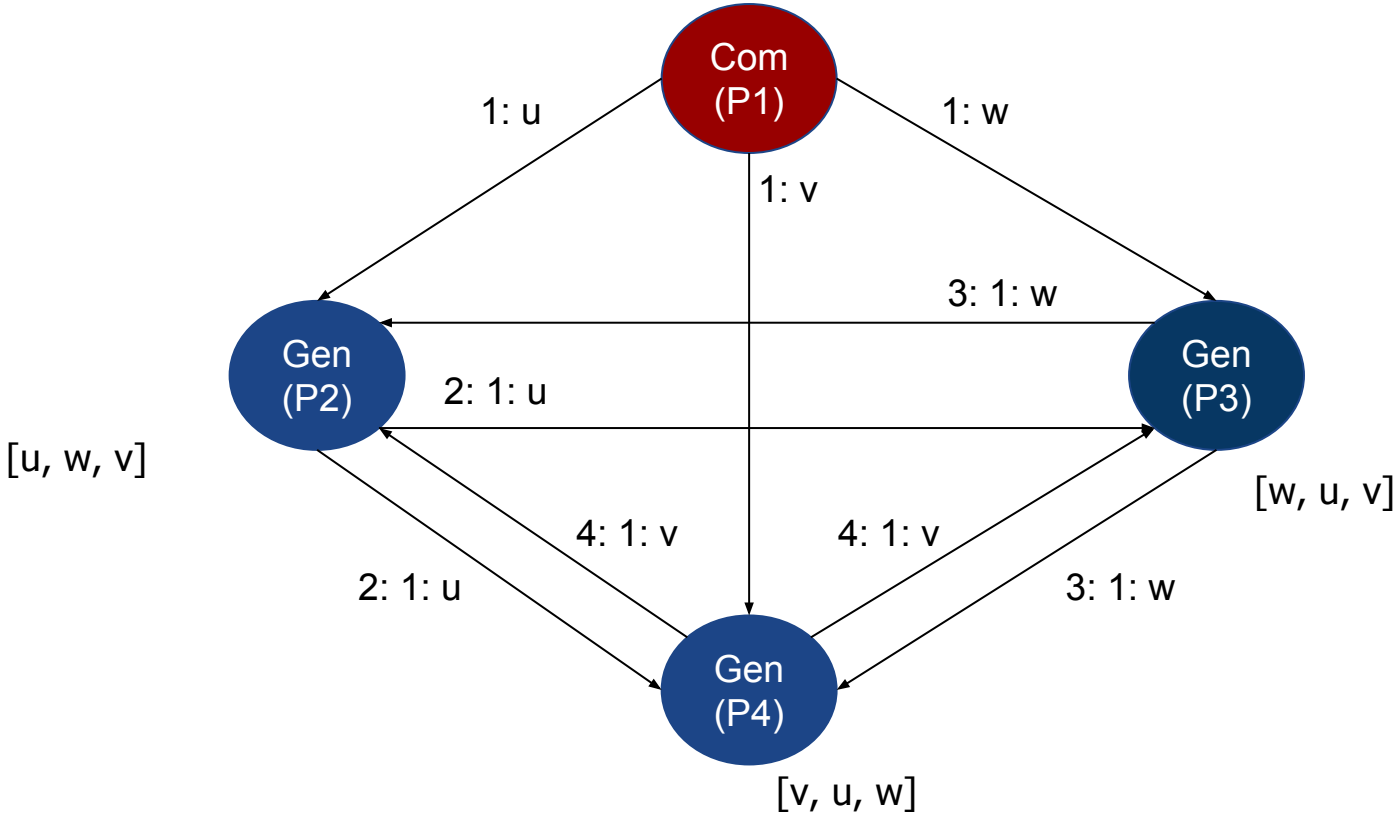

Agenda

- Elección de Líder
- Consenso
- Generales Bizantinos
- **Paxos**

Paxos | Introducción

- **Objetivo**
  - Consensuar un valor aunque múltiples procesos realicen diferentes propuestas
- **Características**
  - **Tolerante a Fallos**
    - Algoritmo progresa siempre que haya una mayoría de procesos vivos
    - N >= 2f + 1 (Fórmula de Quorum)
  - **Posible Rechazar Propuestas**
    - Pedido de un cliente puede ser rechazado
    - Cliente puede reintentar una propuesta las veces que desee

Paxos | Introducción

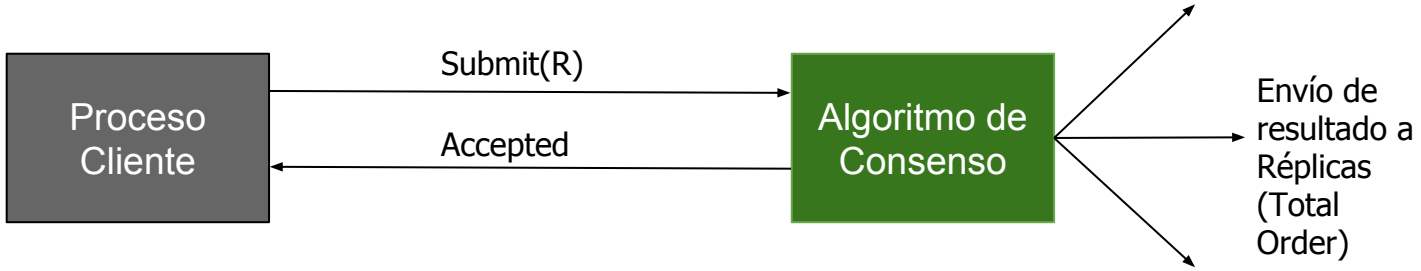

- Cliente intenta setear/modificar un valor R (key/value)
  - Si puede hacerlo, recibe un OK
  - En caso contrario, vuelve a intentar de nuevo

- **Paxos asegura orden consistente en un cluster**
  - Eventos realizados por clientes son almacenados de forma incremental por ID

Paxos | Actores

- **Proposer**
  - Reciben requests de clientes y comienzan el protocolo
  - *Leader* debe ser elegido para evitar *starvation* (para más adelante…)
- **Acceptor**
  - Reciben propuestas/promesas de los Proposers
  - Mantienen el estado del protocolo en almacenamiento estable
  - Quorum: Existe cuando la mayoría de Acceptors se encuentran vivos
- **Learner**
  - Cuando el protocolo llega a un acuerdo, Learner ejecuta el request y envía respuesta al cliente

Paxos | Arquitectura

- **Objetivo**: Lograr que todos los **Acceptors** consensuen un valor **v** asociado a una propuesta realizada por un **Proposer**

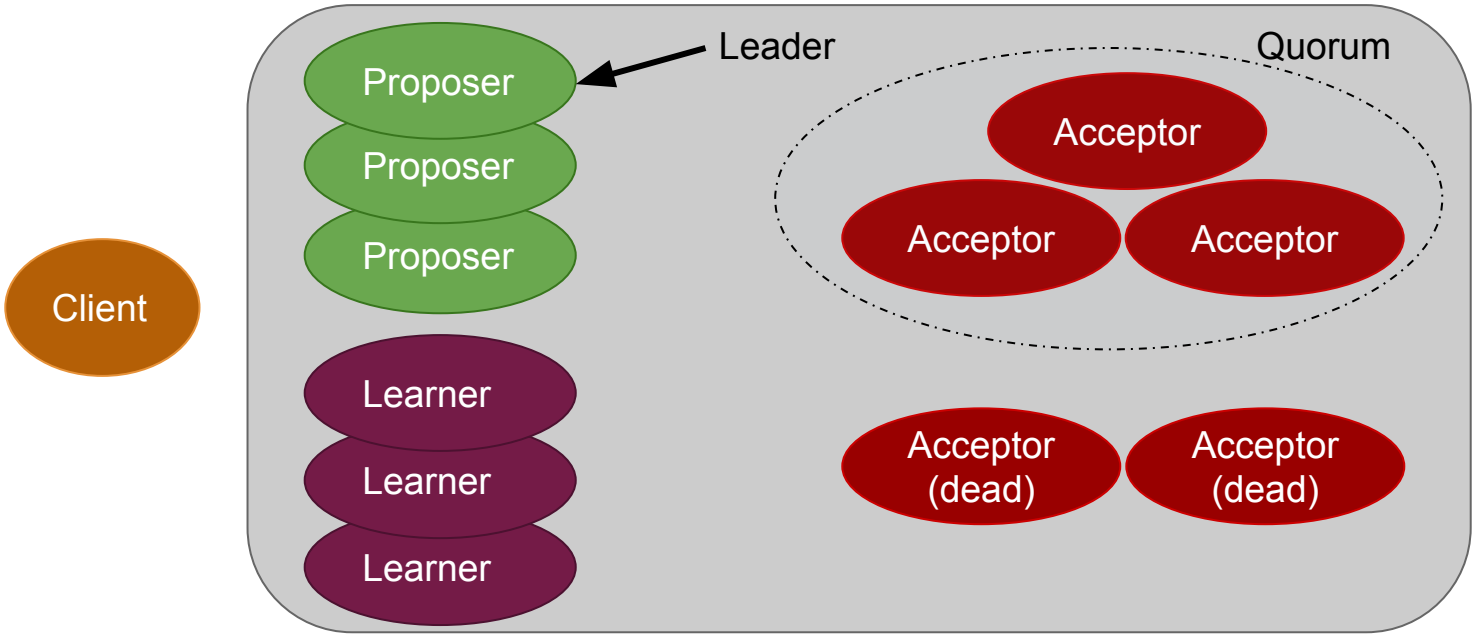

Paxos | Fase 0

- **Client** realiza un Request

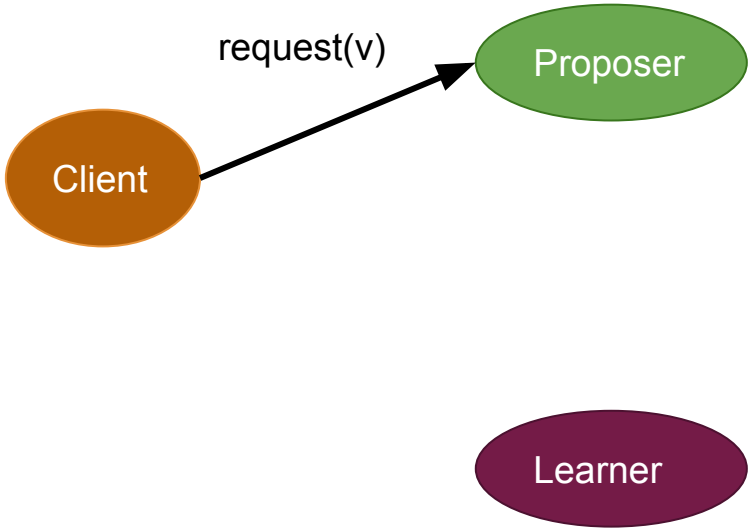

Paxos | Fase 1a - Prepare

- **Proposer**: Crea una propuesta #N donde N es mayor a cualquier propuesta realizada previamente por el Proposer
- Enviar propuesta a Acceptors esperando obtener Quorum (mensaje llegue a la mayoría de Acceptors)

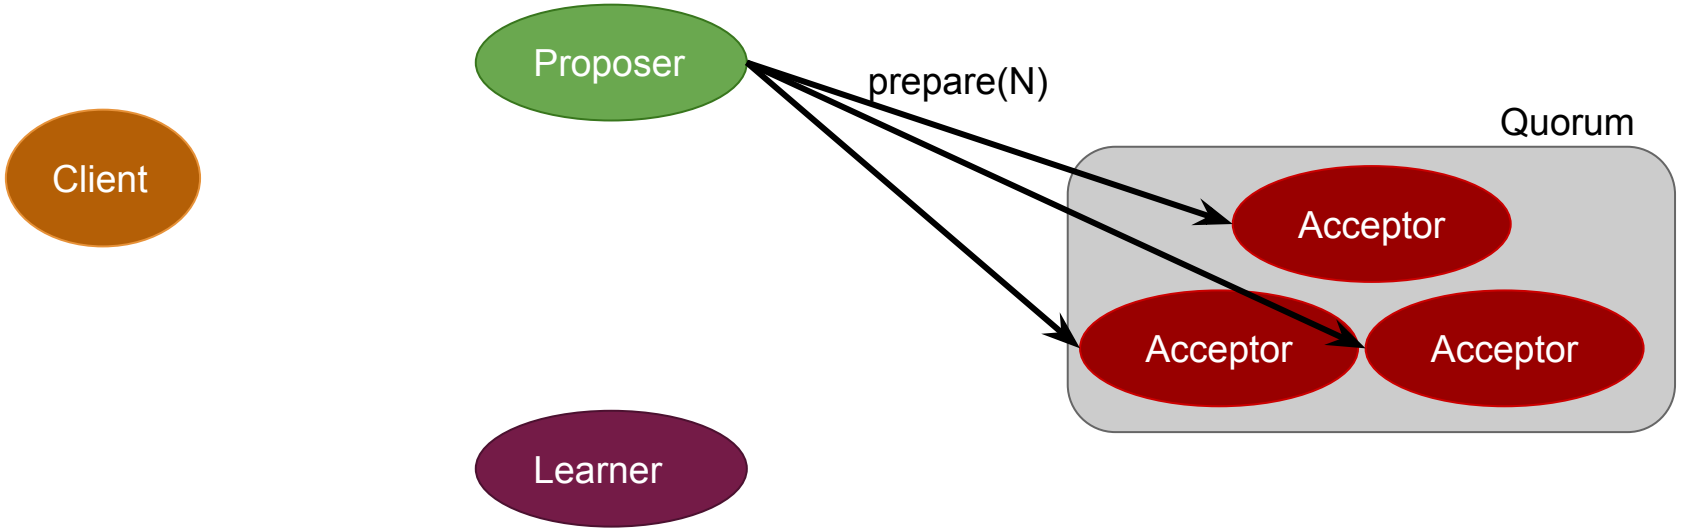

Paxos | Fase 1b - Promise

- Si ID recibido del Proposer es mayor al último recibido, Acceptors prometen rechazar cualquier Requests con ID < N
- Envío de Promesa a Proposer
- Acceptors no contestan si llega una propuesta que no cumpla que N > N'

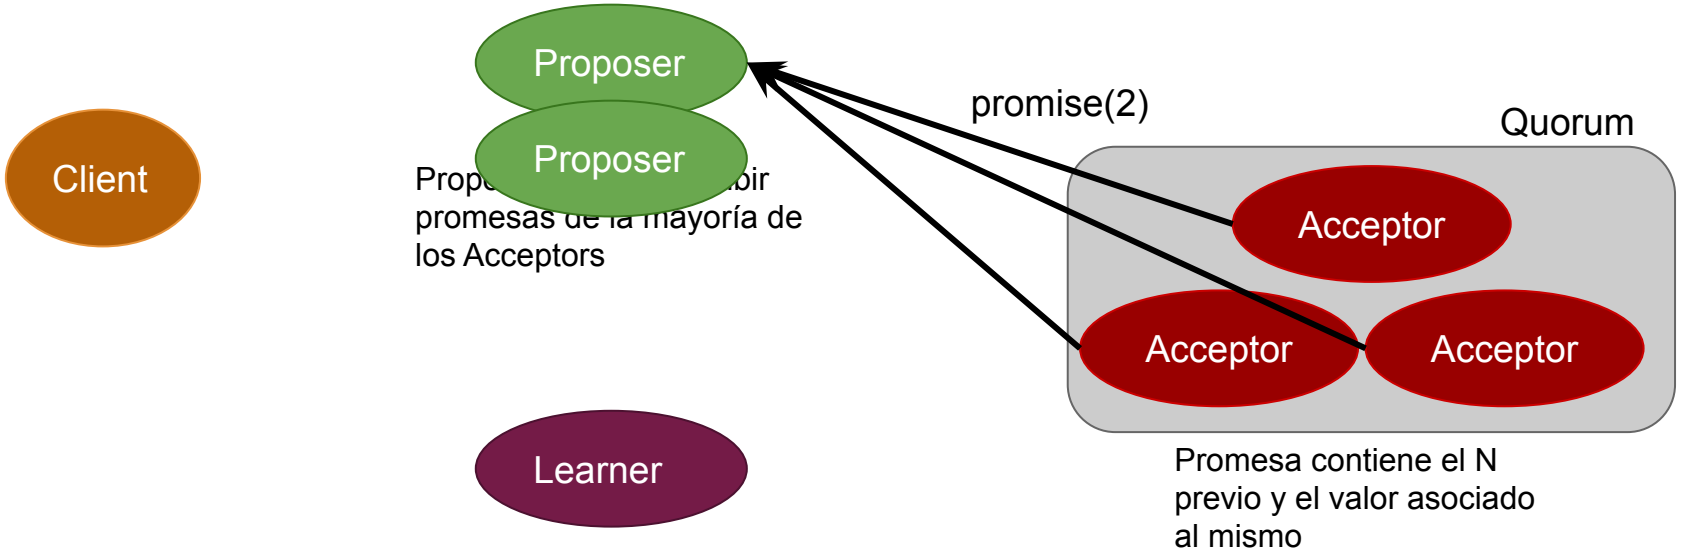

Paxos | Fase 2a - Propose

- **Proposer**: Si recibe Promesas de la mayoría:
  - Rechaza todos los requests con un ID < N
  - envía Propose con el N recibido por los acceptors y un valor v: Propose(N,v)

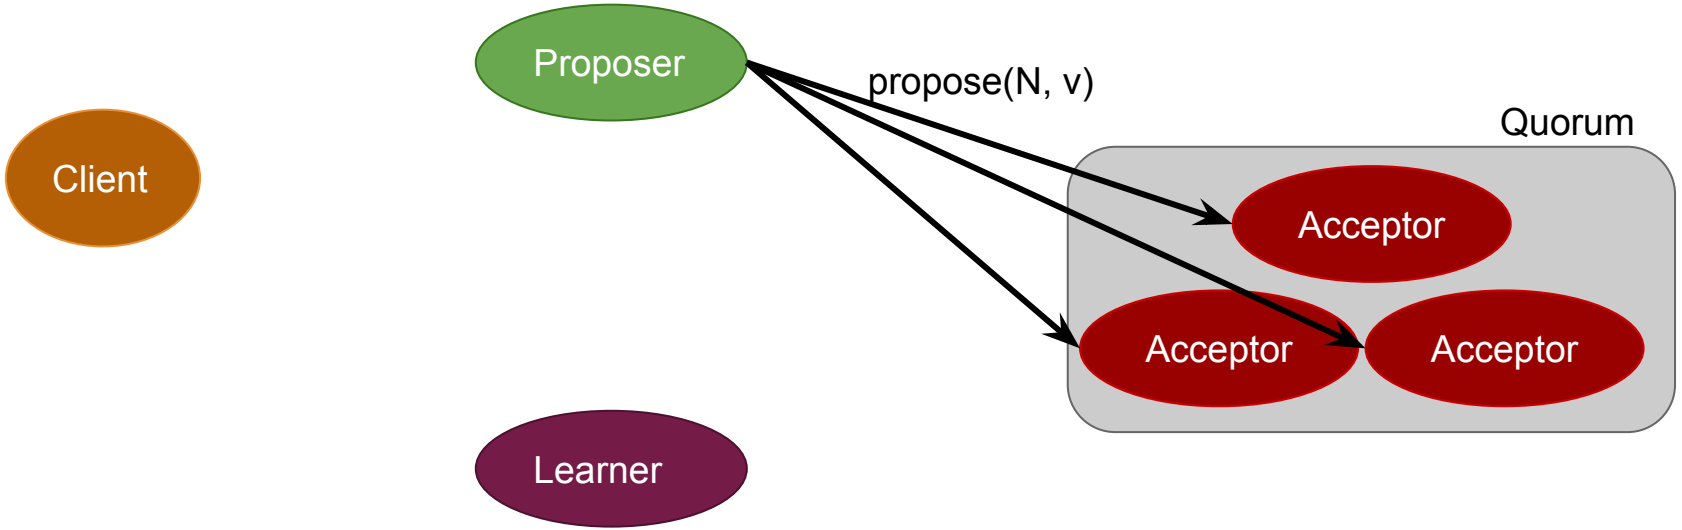

Paxos | Fase 2b - Accept

- **Acceptor:** Si la promesa aún es mantenida, anunciar el nuevo valor v
  - Enviar **accepts** a todos los Learners y al Proposer que envió el request inicial
  - No enviar **accepts** si un ID superior a N fue recibido

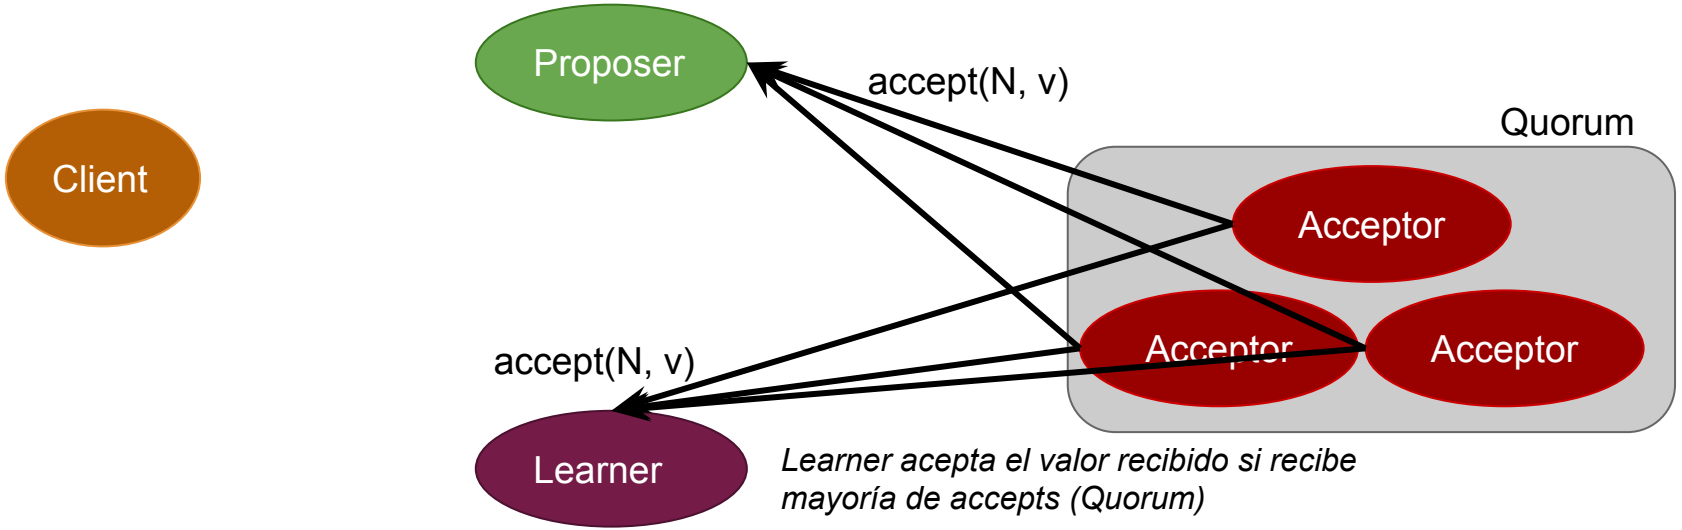

Paxos | Fase 2c - Accept

- **Learner:** Responde al cliente y se toman acciones respecto del valor acordado

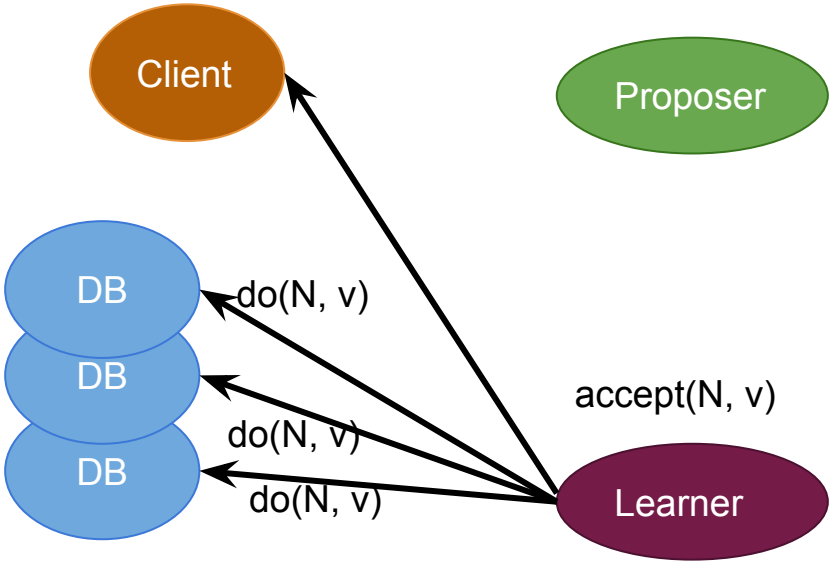

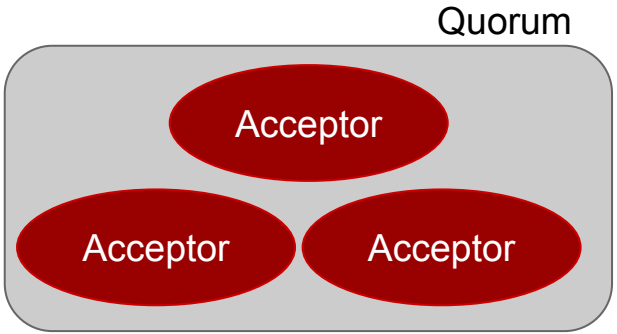

Bibliografía

- P. Verissimo, L. Rodriguez: Distributed Systems for Systems Architects, Kluwer Academic Publishers, 2001.
  - Capítulo 6: Fault-Tolerant System Foundations
  - Capítulo 7: Paradigms for Distributed Fault Tolerance
  - Capítulo 8: Models of Distributed Fault-Tolerant Computing
- G. Coulouris, J. Dollimore, t. Kindberg, G. Blair: Distributed Systems. Concepts and Design, 5th Edition, Addison Wesley, 2012.
  - Capítulo 15: Coordination And Agreement
  - Capítulo 17: Replication
- https://lamport.azurewebsites.net/pubs/paxos-simple.pdf
- The Paxos Algorithm

Bibliografía

- Raft
  - Paper
  - Diapositivas del autor del algoritmo
  - Explicación gráfica, paso a paso
  - Aplicación práctica: Etcd